

MAPSI — cours 3 :
Maximum de vraisemblance
Maximum a posteriori

Pierre-Henri Wuillemin & Nicolas Thome

LIP6 / ISIR – Sorbonne Université, France

- 1 Vraisemblance et prise de décision
- 2 Estimation par maximum de vraisemblance (ML)
- 3 Estimation par maximum a posteriori (MAP)

1 Vraisemblance et prise de décision

Vraisemblance d'un échantillon : loi discrète connue

- Échantillon $\mathbf{x} = (x_1, \dots, x_n)$ de taille n
- Échantillon $\implies$ les x_i = réalisations de variables aléatoires X_i
- Échantillon i.i.d. $\implies$ les X_i sont **mutuellement** indépendants

$$\implies \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n \mathbb{P}(X_i = x_i)$$



l'hypothèse i.i.d est essentielle !

Vraisemblance d'un échantillon dans le cas discret

- $L(\mathbf{x})$ = Vraisemblance de l'échantillon
- $L(\mathbf{x})$ = proba d'obtenir **cet** échantillon sachant la loi P

$$L(\mathbf{x}) = \mathbb{P}(x_1, \dots, x_n) = \prod_{i=1}^n \mathbb{P}(x_i)$$

Vraisemblance d'un échantillon : loi discrète connue

- pièce de monnaie : $\mathbb{P}(\text{Pile}) = 0,75$ et $\mathbb{P}(\text{Face}) = 0,25$
- jet de la pièce $\Rightarrow$ expérience de Bernoulli
 $\Rightarrow$ hypothèse i.i.d. vérifiée



- échantillon 1 :

P	P	F	F	P	P	F	P	P	P
---	---	---	---	---	---	---	---	---	---

$$\begin{aligned}\Rightarrow L(\mathbf{x}) &= \prod_{i=1}^7 \mathbb{P}(\text{Pile}) \times \prod_{i=1}^3 \mathbb{P}(\text{Face}) \\ &= 0,75^7 \times 0,25^3 \approx 0,002086\end{aligned}$$

- échantillon 2 :




F	F	P	P	F	F	P	F	F	F
---	---	---	---	---	---	---	---	---	---

$$\begin{aligned}\Rightarrow L(\mathbf{x}) &= \prod_{i=1}^3 \mathbb{P}(\text{Pile}) \times \prod_{i=1}^7 \mathbb{P}(\text{Face}) \\ &= 0,75^3 \times 0,25^7 \approx 0,000026\end{aligned}$$

Prévention des risques d'inondation (1/4)

- Plan de prévention des risques d'inondations (PPR-I) :

photos satellite SPOT5 $\Rightarrow$ zones susceptibles d'être inondées



- 3 catégories de parcelles :

- 1 inondables (PI)
- 2 partiellement inondables (PPI)
- 3 non inondables (NI)

Prévention des risques d'inondation (2/4)

- images en teintes de gris
- proba d'obtenir un niveau de gris n dépend du type de zone :

$$\mathbb{P}(n|PI) = \mathcal{N}(\mu_{PI}, \sigma_{PI}^2)$$

$$\mu_{PI} = 100 \quad \sigma_{PI} = 20$$

$$\mathbb{P}(n|PPI) = \mathcal{N}(\mu_{PPI}, \sigma_{PPI}^2)$$

$$\mu_{PPI} = 85 \quad \sigma_{PPI} = 5$$

- nouvelle image envoyée par SPOT5 :



- zone Z : niveau de gris = $n = 80$

Problème : zone $Z = PI$ ou PPI ?

Problème : zone $Z = PI$ ou PPI ?

• 2 hypothèses :

① $\Theta_{PI} = \ll Z \text{ est de type } PI \gg$

② $\Theta_{PPI} = \ll Z \text{ est de type } PPI \gg$

• **Idée** : calcul du max de vraisemblance d'obtenir la zone Z
sous Θ_{PI} ou sous Θ_{PPI}

• $L(\mathbf{x}, \Theta_{PI}) = p(80|PI)$, avec p fct de densité de $\mathbb{P}(n|PI) = \mathcal{N}(\mu_{PI}, \sigma_{PI}^2)$

Rappel : la fonction de densité de $\mathcal{N}(\mu, \sigma^2)$ est :

$$p(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \exp \left\{ -\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right\}$$

Problème : zone $Z = PI$ ou PPI ?

$$\bullet \mathbb{P}(n|PI) = \mathcal{N}(\mu_{PI}, \sigma_{PI}^2) = \mathcal{N}(100, 20^2)$$

$$\begin{aligned} L(\mathbf{x}, \Theta_{PI}) &= p(80|PI) \\ &= \frac{1}{\sqrt{2\pi} \times 20} \exp \left\{ -\frac{1}{2} \left(\frac{80-100}{20} \right)^2 \right\} \\ &= \frac{1}{20\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \right\} \\ &\approx 0,0121 \end{aligned}$$

$$\bullet \mathbb{P}(n|PPI) = \mathcal{N}(\mu_{PPI}, \sigma_{PPI}^2) = \mathcal{N}(85, 5^2)$$

$$L(\mathbf{x}, \Theta_{PPI}) = p(80|PPI) = \frac{1}{\sqrt{2\pi} \times 5} \exp \left\{ -\frac{1}{2} \left(\frac{80-85}{5} \right)^2 \right\} \approx 0,0484$$

Max de vraisemblance $\implies PPI$ plus probable

2 ML : Estimation par maximum de vraisemblance

Apprentissage par vraisemblance : le cas discret

- Paramètre à estimer : Θ

Exemple 1 :



$X \in \{\text{pile}, \text{face}\}$

$$\mathbb{P}(X) = \begin{array}{cc} \text{pile} & \text{face} \\ \hline \theta_1 & \theta_2 \end{array} \implies \Theta = \{\theta_1, \theta_2\}$$

Exemple 2 :

recommandations : $r_A \in \{1, 2, 3\}, r_B \in \{a, b\}$

$$\mathbb{P}(r_A, r_B) = \begin{array}{cc} & a & b \\ \hline 1 & \theta_1 & \theta_2 \\ 2 & \theta_3 & \theta_4 \\ 3 & \theta_5 & \theta_6 \end{array} \implies \Theta = \{\theta_1, \dots, \theta_6\}$$

Apprentissage par vraisemblance : le cas discret

- Paramètre à estimer : Θ
- Échantillon $\mathbf{x} = (x_1, \dots, x_n)$ de taille n
- Échantillon $\implies$ les x_i = réalisations de variables aléatoires X_i
- Échantillon i.i.d. $\implies$ les X_i sont **mutuellement** indépendants

$$\implies \mathbb{P}(X_1 = x_1, \dots, X_n = x_n | \Theta = \theta) = \prod_{i=1}^n \mathbb{P}(X_i = x_i | \Theta = \theta)$$

Vraisemblance d'un échantillon dans le cas discret

- $L(\mathbf{x}, \theta)$ = Vraisemblance de l'échantillon
- $L(\mathbf{x}, \theta)$ = proba d'obtenir **cet** échantillon sachant que $\Theta = \theta$

$$L(\mathbf{x}, \theta) = \mathbb{P}(x_1, \dots, x_n | \Theta = \theta) = \prod_{i=1}^n \mathbb{P}(x_i | \Theta = \theta)$$

Vraisemblance d'un échantillon : le cas continu

- Paramètre à estimer : Θ
- Échantillon $\mathbf{x} = (x_1, \dots, x_n)$ de taille n
- Échantillon i.i.d. $\implies$ les X_i sont mutuellement indépendants
- p : fonction de densité

$$\implies p(X_1 = x_1, \dots, X_n = x_n | \Theta = \theta) = \prod_{i=1}^n p(X_i = x_i | \Theta = \theta)$$

Vraisemblance d'un échantillon dans le cas continu

- $L(\mathbf{x}, \theta) =$ Vraisemblance de l'échantillon
- $L(\mathbf{x}, \theta) = p(x_1, \dots, x_n | \Theta = \theta) = \prod_{i=1}^n p(x_i | \Theta = \theta)$

Apprentissage de Θ par vraisemblance (1/2)

- pièce de monnaie : $\mathbb{P}(\text{Pile}) = \theta_1 = ???$ et $\mathbb{P}(\text{Face}) = \theta_2 = ???$
- paramètre $\Theta = \{\theta_1, \theta_2\} = \{\theta_1, 1 - \theta_1\} = \{\theta_1\}$
- échantillon :

P	P	F	F	P	P	F	P	P	P
---	---	---	---	---	---	---	---	---	---

$$\implies L(\mathbf{x}, \Theta) = \prod_{i=1}^7 \mathbb{P}(\text{Pile}|\Theta) \times \prod_{i=1}^3 \mathbb{P}(\text{Face}|\Theta) = \theta^7(1 - \theta)^3$$


- $\theta_A = 0,75 \implies L(\mathbf{x}, \theta_A) = 0,75^7 \times 0,25^3 \approx 0,002086$
- $\theta_B = 0,5 \implies L(\mathbf{x}, \theta_B) = 0,5^7 \times 0,5^3 \approx 0,000977$
- $\theta_C = 0,25 \implies L(\mathbf{x}, \theta_C) = 0,25^7 \times 0,75^3 \approx 0,000026$

$\implies \theta_A$ plus vraisemblable que θ_B ou θ_C

L'échantillon a été généré par une pièce biaisée avec
 $\mathbb{P}(\text{Pile}) = \theta_A = 0,75$

Apprentissage de Θ par vraisemblance (2/2)

$$L(\mathbf{x}, \Theta) = \theta^7(1 - \theta)^3$$



solution optimale : $\mathbb{P}(\text{Pile}) = \theta^* = 0,7$

Estimateur du maximum de vraisemblance

- X : variable aléatoire sur la population
- X suit une loi de proba de paramètre Θ inconnu
- Θ : ensemble des valeurs possibles pour θ
- $\mathbf{x}$: échantillon i.i.d.
- $T = f(X) = \textit{estimateur du maximum de vraisemblance}$
défini par $\mathbf{x} \mapsto t = f(\mathbf{x}) = \underset{\theta \in \Theta}{\text{Argmax}} L(\mathbf{x}, \theta)$

$\implies t = \text{valeur } \theta \text{ de } \Theta \text{ pour laquelle la proba d'observer } \mathbf{x} \text{ était la plus grande}$

Calcul du maximum de vraisemblance

Problème : comment calculer le maximum de vraisemblance ?

- $\underset{\theta \in \Theta}{\operatorname{Argmax}} L(\mathbf{x}, \theta) = \underset{\theta \in \Theta}{\operatorname{Argmax}} \mathbb{P}(x_1, \dots, x_n | \theta) = \underset{\theta \in \Theta}{\operatorname{Argmax}} \prod_{i=1}^n \mathbb{P}(x_i | \theta)$

- Certaines conditions de concavité et de dérivabilité

$$\implies \underset{\theta \in \Theta}{\operatorname{Argmax}} L(\mathbf{x}, \theta) \text{ obtenu lorsque } \frac{\partial L(\mathbf{x}, \theta)}{\partial \theta} = 0$$

- $\underset{\theta \in \Theta}{\operatorname{Argmax}} L(\mathbf{x}, \theta) = \underset{\theta \in \Theta}{\operatorname{Argmax}} \ln L(\mathbf{x}, \theta) = \underset{\theta \in \Theta}{\operatorname{Argmax}} \sum_{i=1}^n \ln \mathbb{P}(x_i | \theta)$

$\underset{\theta \in \Theta}{\operatorname{Argmax}} \ln L(\mathbf{x}, \theta) = \text{maximum de la log vraisemblance}$

$$\implies \underset{\theta \in \Theta}{\operatorname{Argmax}} L(\mathbf{x}, \theta) \text{ obtenu lorsque } \sum_{i=1}^n \frac{\partial \ln \mathbb{P}(x_i | \theta)}{\partial \theta} = 0$$

- pièce de monnaie
- $X \in \{0, 1\}$, $0 \iff \text{Face}$, $1 \iff \text{Pile}$
- $X \sim \mathcal{B}(1, p) \implies \mathbb{P}(X = x|p) = p^x(1 - p)^{1-x}$
- n lancers de la pièce $\implies$ observations $\mathbf{x} = \{x_1, \dots, x_n\}$
- $\mathbb{P}(\mathbf{x}|p) = \prod_{i=1}^n \mathbb{P}(x_i|p) = \prod_{i=1}^n p^{x_i}(1 - p)^{1-x_i}$

Problème : à partir de $\mathbf{x}$, peut-on raisonnablement déduire p ?

- maximum de vraisemblance :

$$\ln \mathbb{P}(\mathbf{x}|p) = \sum_{i=1}^n [x_i \ln p + (1 - x_i) \ln(1 - p)]$$

$$\frac{\partial \ln \mathbb{P}(\mathbf{x}|p)}{\partial p} = \frac{1}{p} \sum_{i=1}^n x_i - \frac{n - \sum_{i=1}^n x_i}{1 - p} = 0 \implies p_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$$

Max de vraisemblance et loi normale (1/2)

- $X \sim \mathcal{N}(\mu, \sigma^2)$; on suppose $\sigma = 1$
- paramètre $\Theta =$ espérance μ
- loi normale $\implies$ vraisemblance :

$$L(\mathbf{x}, \theta) = \prod_{i=1}^n p(x_i | \theta) = \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} (x_i - \theta)^2 \right\} \right]$$

- $\frac{\partial L(\mathbf{x}, \theta)}{\partial \theta} = 0 \iff \frac{\partial \ln L(\mathbf{x}, \theta)}{\partial \theta} = 0$

- $\ln L(\mathbf{x}, \theta) = -\frac{n}{2} \ln 2\pi - \frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2$

- $\frac{\partial L(\mathbf{x}, \theta)}{\partial \theta} = 0 \iff \sum_{i=1}^n (x_i - \theta) = 0 \iff \theta = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$

Estimateur du maximum de vraisemblance : $\bar{X}$

Max de vraisemblance et loi normale (2/2)

- $X \sim \mathcal{N}(\mu, \sigma^2)$
- paramètre $\Theta = (\mu, \sigma^2)$
- Log vraisemblance :

$$\ln L(\mathbf{x}, \theta) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

- Maximum de vraisemblance $\implies \frac{\partial L(\mathbf{x}, \theta)}{\partial \mu} = 0$ et $\frac{\partial L(\mathbf{x}, \theta)}{\partial \sigma^2} = 0$


$$\bullet \left\{ \begin{array}{l} \frac{\partial L(\mathbf{x}, \theta)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \mu = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \\ \frac{\partial L(\mathbf{x}, \theta)}{\partial \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \implies \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = s_n^2 \end{array} \right.$$

Estimateurs du maximum de vraisemblance : $\bar{X}$ et S_n^2



estimateur de la variance biaisé : variance non corrigée

Problème d'ajustement (1/6)



Observations

(x_1, t_1)
 $\vdots$
 (x_{10}, t_{10})


$\Rightarrow$ courbe $\sin(2\pi x) \Rightarrow$ estimation de t_{11}

$\Rightarrow$ reconnaissance de la courbe verte

Problème d'ajustement (2/6)


Idée : estimer la courbe verte par un polynôme :

$$y(x, \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \cdots + w_M x^M = \sum_{j=0}^M w_j x^j$$



Problème d'ajustement (3/6)

Idée : les ordonnées des points bleus sont distribuées selon une loi normale autour de $y(x, \mathbf{w})$:



$$\Rightarrow \mathbb{P}(t|x, \mathbf{w}, \sigma^2) = \mathcal{N}(t|y(x, \mathbf{w}), \sigma^2)$$

Problème : comment trouver $\mathbf{w}$ et σ^2 ?

$\Rightarrow$ par maximum de vraisemblance

$$\mathbb{P}(t|x, \mathbf{w}, \sigma^2) = \mathcal{N}(t|y(x, \mathbf{w}), \sigma^2)$$

- observations $\{(x_i, t_i), i = 1, \dots, n\}$
- $\mathbf{t} = \{t_1, \dots, t_n\}$; $\mathbf{x} = \{x_1, \dots, x_n\}$
- observations $\implies$ échantillon i.i.d

$$\begin{aligned}\implies \mathbb{P}(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) &= \prod_{i=1}^n \mathbb{P}(t_i|x_i, \mathbf{w}, \sigma^2) \\ &= \prod_{i=1}^n \mathcal{N}(t_i|y(x_i, \mathbf{w}), \sigma^2)\end{aligned}$$


- Max de vraisemblance $\implies$ calculer la log-vraisemblance :

$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 + \frac{n}{2} \ln \frac{1}{\sigma^2} - \frac{n}{2} \ln(2\pi)$$

Problème d'ajustement (5/6)

$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 + \frac{n}{2} \ln \frac{1}{\sigma^2} - \frac{n}{2} \ln(2\pi)$$

- Maximum de log-vraisemblance $\Rightarrow$ trouver $\mathbf{w}_{ML}$ et σ_{ML}^2 qui maximisent $\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)$
- maximiser par rapport à $\mathbf{w}_{ML} \iff$ minimiser $\sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2$



$\Rightarrow$ Moindres carrés

$$\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 + \frac{n}{2} \ln \frac{1}{\sigma^2} - \frac{n}{2} \ln(2\pi)$$

- maximiser $\ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)$ par rapport à $\sigma^2 \Rightarrow \frac{\partial \ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)}{\partial \sigma^2} = 0$

- $\frac{\partial \ln p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \sigma^2)}{\partial \sigma^2} = \frac{1}{2\sigma^4} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2 - \frac{n}{2\sigma^4} \sigma^2 = 0$

$$\Rightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n [y(x_i, \mathbf{w}) - t_i]^2$$

$$\sigma_{ML}^2 = \frac{1}{n} \sum_{i=1}^n [y(x_i, \mathbf{w}_{ML}) - t_i]^2$$

3 MAP : Estimation par maximum a posteriori

$$p_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$$

- 3 lancers $\implies$ observations : {Pile,Pile,Pile}



- Maximum de vraisemblance $\implies p_{ML} = 1$

$\implies$ on considère que tout lancer de la pièce devrait tomber sur Pile

$\implies$ résultat à l'encontre du bon sens

$\implies$ autre estimateur : maximum a posteriori

Le modèle bayésien (1/4)

Maximum a posteriori $\implies$ modèle bayésien

Modèle bayésien

événements : parties de $\mathcal{X} \times \Theta$, où :

- $\mathcal{X}$ = l'espace des observations (échantillons) $\mathbf{x}$ de taille n
- Θ = espace des paramètres θ
- famille des événements dotée d'une loi de proba Π

- *cas discret* : Π déterminée par les probas des événements élémentaires $\pi(\mathbf{x}, \theta)$
- *cas continu* : Π déterminée par la densité jointe $\pi(\mathbf{x}, \theta)$



Max de vraisemblance : $\pi(\mathbf{x}|\theta)$ au lieu de $\pi(\mathbf{x}, \theta) = \pi(\mathbf{x}|\theta)\pi(\theta)$

Le modèle bayésien (2/4)

Le cas discret :

- $\pi(\mathbf{x}, \theta) = \Pi(X = \mathbf{x}, \Theta = \theta)$, où X, Θ variables aléatoires
- $\pi(\mathbf{x}) = \Pi(X = \mathbf{x}) = \sum_{\theta \in \Theta} \Pi(X = \mathbf{x}, \Theta = \theta) = \sum_{\theta \in \Theta} \pi(\mathbf{x}, \theta)$
- $\pi(\theta) = \Pi(\Theta = \theta) = \sum_{\mathbf{x} \in \mathcal{X}} \Pi(X = \mathbf{x}, \Theta = \theta) = \sum_{\mathbf{x} \in \mathcal{X}} \pi(\mathbf{x}, \theta)$
- $\pi(\mathbf{x}|\theta) = \Pi(X = \mathbf{x}|\Theta = \theta) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\theta)}$
- $\pi(\theta|\mathbf{x}) = \Pi(\Theta = \theta|X = \mathbf{x}) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\mathbf{x})}$

Probabilités a priori et a posteriori

- $\pi(\theta)$ = probabilité a priori de θ
- $\pi(\theta|\mathbf{x})$ = probabilité a posteriori de θ

Le cas continu :

- $\pi(\mathbf{x}) = \Pi(X = \mathbf{x}) = \int_{\theta \in \Theta} \Pi(X = \mathbf{x}, \Theta = \theta) d\theta = \int_{\theta \in \Theta} \pi(\mathbf{x}, \theta) d\theta$
- $\pi(\theta) = \Pi(\Theta = \theta) = \int_{\mathbf{x} \in \mathcal{X}} \Pi(X = \mathbf{x}, \Theta = \theta) d\mathbf{x} = \int_{\mathbf{x} \in \mathcal{X}} \pi(\mathbf{x}, \theta) d\mathbf{x}$
- $\pi(\mathbf{x}|\theta) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\theta)}$
- $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}, \theta)}{\pi(\mathbf{x})}$

Probabilités a priori et a posteriori

- $\pi(\theta)$ = probabilité a priori de Θ
= idée que l'on se fait de Θ avant observation
- $\pi(\theta|\mathbf{x})$ = probabilité a posteriori de Θ
= idée que l'on se fait de Θ après observation

- Formule de Bayes : $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\pi(\mathbf{x})}$

- $$\begin{cases} \text{cas discret : } \pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\sum_{\theta \in \Theta} \pi(\mathbf{x}, \theta)} = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\sum_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta)} \\ \text{cas continu : } \pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\int_{\theta \in \Theta} \pi(\mathbf{x}, \theta) d\theta} = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\int_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta) d\theta} \end{cases}$$

- **Rappel** : $\pi(\mathbf{x}|\theta) = \text{vraisemblance de l'échantillon} = L(\mathbf{x}, \theta)$

Maximum a posteriori (MAP)

T estimateur du maximum a posteriori de Θ :

défini par $\mathbf{x} \mapsto t = \underset{\theta \in \Theta}{\operatorname{Argmax}} \pi(\theta|\mathbf{x})$

- échantillon i.i.d de n observations

- $X = (X_1, \dots, X_n) \implies \mathbf{x} = (x_1, \dots, x_n)$ observation de X

- $$\begin{cases} \text{cas discret : } \pi(\theta|\mathbf{x}) = \frac{L(\mathbf{x}, \theta)\pi(\theta)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \\ \text{cas continu : } \pi(\theta|\mathbf{x}) = \frac{L(\mathbf{x}, \theta)\pi(\theta)}{\int_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)d\theta} \end{cases}$$

- échantillon i.i.d $\implies \pi(\mathbf{x}|\theta) = L(\mathbf{x}, \theta) = \begin{cases} \prod_{i=1}^n \mathbb{P}(x_i|\theta) & (\text{discret}) \\ \prod_{i=1}^n p(x_i|\theta) & (\text{continu}) \end{cases}$

MAP : retour sur la pièce de monnaie (1/6)

- pièce de monnaie $\implies X \in \{0, 1\}$

0 $\iff$ Face



1 $\iff$ Pile



- $X \sim \mathcal{B}(1, \theta) \implies \mathbb{P}(X = x|\theta) = \theta^x(1 - \theta)^{1-x}$
- échantillon $\mathbf{x}$ de 3 lancers $\implies \{\text{Pile}, \text{Pile}, \text{Pile}\}$
- Max de vraisemblance $\implies \theta_{ML} = 1$



$\implies$ tous les lancers devraient tomber sur Pile

-
- Modèle bayésien : $\Theta = \{\theta_A = 1, \theta_B = 2/3, \theta_C = 1/2, \theta_D = 1/3\}$
 - Info a priori : $\pi(\theta_A) = \frac{1}{32}, \pi(\theta_B) = \frac{1}{4}, \pi(\theta_C) = \frac{1}{2}, \pi(\theta_D) = \frac{7}{32}$

Problème : quelle est la valeur du maximum a posteriori ?

MAP : retour sur la pièce de monnaie (2/6)

- Modèle bayésien : $\Theta = \{\theta_A = 1, \theta_B = 2/3, \theta_C = 1/2, \theta_D = 1/3\}$

- $L(\mathbf{x}, \theta_A) = \pi(\mathbf{x}|\theta_A) = \prod_{i=1}^3 \mathbb{P}(x_i|\theta_A) = 1^3 \times 0^0 = 1$

(convention : $0^0 = 1$, aucun échec observé sur les 3 lancers)

- $L(\mathbf{x}, \theta_B) = \pi(\mathbf{x}|\theta_B) = \prod_{i=1}^3 \mathbb{P}(x_i|\theta_B) = \left(\frac{2}{3}\right)^3 \times \left(1 - \frac{2}{3}\right)^0 = \left(\frac{2}{3}\right)^3 \approx 0,296$

- $L(\mathbf{x}, \theta_C) = \pi(\mathbf{x}|\theta_C) = \prod_{i=1}^3 \mathbb{P}(x_i|\theta_C) = \left(\frac{1}{2}\right)^3 \times \left(1 - \frac{1}{2}\right)^0 = \left(\frac{1}{2}\right)^3 = 0,125$

- $L(\mathbf{x}, \theta_D) = \pi(\mathbf{x}|\theta_D) = \prod_{i=1}^3 \mathbb{P}(x_i|\theta_D) = \left(\frac{1}{3}\right)^3 \times \left(1 - \frac{1}{3}\right)^0 = \left(\frac{1}{3}\right)^3 \approx 0,037$

MAP : retour sur la pièce de monnaie (3/6)

- Info a priori : $\pi(\theta_A) = \frac{1}{32}$, $\pi(\theta_B) = \frac{1}{4}$, $\pi(\theta_C) = \frac{1}{2}$, $\pi(\theta_D) = \frac{7}{32}$

- $\pi(\theta_A|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_A)\pi(\theta_A)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto 1 \times \frac{1}{32} = 0,03125$

- $\pi(\theta_B|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_B)\pi(\theta_B)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto \left(\frac{2}{3}\right)^3 \times \frac{1}{4} \approx 0,074$

- $\pi(\theta_C|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_C)\pi(\theta_C)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto \left(\frac{1}{2}\right)^3 \times \frac{1}{2} = 0,0625$

- $\pi(\theta_D|\mathbf{x}) = \frac{L(\mathbf{x}, \theta_D)\pi(\theta_D)}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)} \propto \left(\frac{1}{3}\right)^3 \times \frac{7}{32} \approx 0,008$


Max a posteriori : $\Theta = \theta_B \implies X \sim \mathcal{B}(1, \theta_B) = \mathcal{B}(1, 2/3)$



probabilité que la pièce tombe sur Face $\neq 0$

MAP : retour sur la pièce de monnaie (4/6)


- Modèle bayésien : $\Theta \in [0, 1]$
- Info a priori : $\Theta \sim$ loi normale tronquée ($\mu = 1/2, \sigma = 1/4$) :
- densité : $\pi(\theta) = \begin{cases} \frac{1}{0,9544} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2\right) & \text{si } \theta \in [0, 1] \\ 0 & \text{sinon} \end{cases}$



MAP : retour sur la pièce de monnaie (5/6)

$$\pi(\theta|\mathbf{x}) = \frac{L(\mathbf{x}, \theta)\pi(\theta)}{\int_{\theta' \in \Theta} L(\mathbf{x}, \theta')\pi(\theta')} \propto L(\mathbf{x}, \theta)\pi(\theta) = \theta^3 \times \pi(\theta)$$

$$\propto \begin{cases} \theta^3 \times \frac{1}{0,9544} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2\right) & \text{si } \theta \in [0, 1] \\ 0 & \text{sinon} \end{cases}$$



solution optimale : $\theta = 0,75$

$$\pi(\theta|\mathbf{x}) \propto \theta^3 \times \frac{1}{0,9544} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2\right) \text{ pour } \theta \in [0, 1]$$

$$\implies \log \pi(\theta|\mathbf{x}) = 3 \log \theta - \frac{1}{2} \left(\frac{\theta-\mu}{\sigma}\right)^2 + \text{constante}$$

$$\implies \frac{\partial \log \pi(\theta|\mathbf{x})}{\partial \theta} = \frac{3}{\theta} - \frac{\theta-\mu}{\sigma^2}$$

$$\implies \frac{\partial \log \pi(\theta|\mathbf{x})}{\partial \theta} = 0 \Leftrightarrow \theta^2 - \mu\theta - 3\sigma^2 = 0$$

$$\implies \theta = 0,75$$

calcul de la distribution a posteriori : $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\int_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta)d\theta}$

$\Rightarrow$ si $\pi(\mathbf{x}|\theta)\pi(\theta)$ est analytiquement complexe, alors le calcul de l'intégrale est compliqué

Lois conjuguées

- $\pi(\theta)$: loi a priori
- $\pi(\mathbf{x}|\theta)$: fonction de vraisemblance
- $\pi(\theta|\mathbf{x})$: distribution a posteriori
- $\pi(\theta)$ et $\pi(\mathbf{x}|\theta)$ sont conjuguées si $\pi(\theta|\mathbf{x})$ appartient à la même famille de lois que $\pi(\theta)$

Lois conjuguées : exemple de la pièce de monnaie

• pièce de monnaie $\Rightarrow X \in \{0, 1\} : 0 \iff$



$1 \iff$



• $X \sim \mathcal{B}(1, \theta) \Rightarrow$ vraisemblance d'un échantillon :

$$\pi(\mathbf{x}|\theta) = \theta^x (1 - \theta)^{n-x}, \text{ avec } x = \#(x_i = 1)$$

$\Rightarrow$ loi binomiale

Distribution de probabilité Beta

$$\text{Loi Beta : } \text{Beta}(\theta, a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1} (1-\theta)^{b-1}$$

$$\text{avec } \Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt$$





$$\text{Espérance} = \frac{a}{a+b} \quad \text{Variance} = \frac{ab}{(a+b)^2(a+b+1)}$$

$\Rightarrow$ loi Beta et loi binomiales conjuguées

Lois conjuguées : loi binomiale et loi Beta

- loi a priori : $\pi(\theta) = \text{Beta}(\theta, a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1} (1-\theta)^{b-1}$
- fonction de vraisemblance : $\pi(\mathbf{x}|\theta) = \theta^x (1-\theta)^{n-x}$, avec $x = \sum (x_i = 1)$
- loi a posteriori : $\pi(\theta|\mathbf{x}) = \frac{\pi(\mathbf{x}|\theta)\pi(\theta)}{\sum_{\theta \in \Theta} \pi(\mathbf{x}|\theta)\pi(\theta)} \propto \pi(\mathbf{x}|\theta)\pi(\theta)$
- loi a posteriori : $\pi(\theta|\mathbf{x}) \propto \theta^{x+a-1} (1-\theta)^{b+n-x-1}$

$$\implies \pi(\theta|\mathbf{x}) \sim \text{Beta}(\theta, x+a, b+n-x)$$



Comparaison MAP – maximum de vraisemblance

- pièce de monnaie $\Rightarrow X \in \{0, 1\} : 0 \iff$



$1 \iff$



- Max de vraisemblance :

$$\pi(\mathbf{x}|\theta) = \theta^x(1 - \theta)^{n-x} \Rightarrow \text{Beta}(\theta, x + 1, n - x + 1)$$

- Max a posteriori :

$$\pi(\theta|\mathbf{x}) \propto \theta^{x+a-1}(1 - \theta)^{b+n-x-1} \Rightarrow \text{Beta}(\theta, x + a, n - x + b)$$

$\Rightarrow$ Max de vraisemblance $\iff$ Max a posteriori avec $a = 1$ et $b = 1$

Or $\text{Beta}(\theta, 1, 1) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} = \text{constante}$

Max de vraisemblance $\iff$ Max a posteriori avec a priori uniforme



$n \rightarrow +\infty \Rightarrow \text{max de vraisemblance} \approx \text{max a posteriori}$

$\Rightarrow$ l'a priori devient négligeable

Loi normale et loi conjuguée

- fonction de vraisemblance = loi normale, μ connue, on estime la précision $\tau = 1/\sigma^2$

$\implies$ loi a priori conjuguée pour τ : loi Γ

La loi Γ

- $X \sim \Gamma(x, k, \theta)$
- fonction de densité de la loi Γ :


$$f(x, k, \theta) = x^{k-1} \frac{e^{-x/\theta}}{\theta^k \Gamma(k)} \quad \forall x, k, \theta > 0$$

- $\Gamma(k) = \int_0^{+\infty} t^{k-1} e^{-t} dt$
- $\mathbb{E}(X) = k\theta, \quad \mathbb{V}(X) = k\theta^2$



Lorsque k entier : $\Gamma(x, k, \theta)$ = loi de k variables indépendantes suivant une loi exponentielle d'espérance θ



- Familles de lois conjuguées :
http://en.wikipedia.org/wiki/Conjugate_prior



Prévention des risques d'inondation (1/3)

- Plan de prévention des risques d'inondations (PPR-I) :

photos satellite SPOT5 $\implies$ zones susceptibles d'être inondées



- 3 catégories de parcelles :

- 1 inondables (PI)
- 2 partiellement inondables (PPI)
- 3 non inondables (NI)

Prévention des risques d'inondation (2/3)

- images en teintes de gris
- proba d'obtenir un niveau de gris n dépend du type de zone :

$$\mathbb{P}(n|PI) = \mathcal{N}(100, 20^2) \quad \mathbb{P}(n|PPI) = \mathcal{N}(85, 5^2)$$

- nouvelle image envoyée par SPOT5 :



- zone Z : niveau de gris = $n = 80$
- **Connaissance a priori** : 60% de PI , 10% de PPI , 30% de NI

Problème : zone $Z = PI$ ou PPI ?

Problème : zone $Z = PI$ ou PPI ?

- 2 hypothèses :

- 1 $\Theta_{PI} = \text{« } Z \text{ est de type } PI \text{ »}$
- 2 $\Theta_{PPI} = \text{« } Z \text{ est de type } PPI \text{ »}$

- **Idée** : calcul du MAP d'obtenir la zone Z sous Θ_{PI} ou sous Θ_{PPI}

- $\pi(\Theta_{PI}|\mathbf{x}) = \frac{L(\mathbf{x}, \Theta_{PI})\pi(\Theta_{PI})}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$ $\pi(\Theta_{PPI}|\mathbf{x}) = \frac{L(\mathbf{x}, \Theta_{PPI})\pi(\Theta_{PPI})}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$

- Rappel : $L(\mathbf{x}, \Theta_{PI}) \approx 0,0121$ $L(\mathbf{x}, \Theta_{PPI}) \approx 0,0484$



- a priori : $\pi(\Theta_{PI}) = 0,6$ $\pi(\Theta_{PPI}) = 0,1$

- $\pi(\Theta_{PI}|\mathbf{x}) = \frac{0,0121 \times 0,6}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$ $\pi(\Theta_{PPI}|\mathbf{x}) = \frac{0,0484 \times 0,1}{\sum_{\theta \in \Theta} L(\mathbf{x}, \theta)\pi(\theta)}$

MAP $\Rightarrow$ parcelle inondable (PI)

Analyse d'un trafic réseau (1/4)

● Réseau informatique : transfert de paquets



● **Problème** : analyse des paquets perdus sur un sous-réseau

● X : variable aléatoire « nombre de paquets envoyés jusqu'à bonne réception »

● X loi géométrique : $\mathbb{P}(X = n) = (1 - p)^{n-1}p$

p : probabilité qu'un paquet soit correctement transmis

- observation de 7 réalisations de X :

2	3	8	3	4	7	8
---	---	---	---	---	---	---

Estimation de p ?

- 1 estimation par ML
- 2 estimation par MAP

1 estimation par max de vraisemblance

2	3	8	3	4	7	8
---	---	---	---	---	---	---

● vraisemblance : $L(\mathbf{x}, \theta) = \prod_{i=1}^7 \mathbb{P}(x_i|\theta)$

θ = estimation de p

● observations $\implies L(\mathbf{x}, \theta) = (1 - \theta)^{28} \theta^7$

$$\implies \ln L(\mathbf{x}, \theta) = 28 \ln(1 - \theta) + 7 \ln \theta$$

$$\implies \frac{\partial \ln L(\mathbf{x}, \theta)}{\partial \theta} = \frac{-28}{1 - \theta} + \frac{7}{\theta} = \frac{7 - 35\theta}{\theta(1 - \theta)}$$

$$\implies \text{maximum de vraisemblance} = \theta = 0,2$$

2 estimation par MAP

2	3	8	3	4	7	8
---	---	---	---	---	---	---

- A priori : $\pi(\theta) = \text{Beta}(\theta, 2, 15) = \frac{\Gamma(17)}{\Gamma(2)\Gamma(15)}\theta^1(1-\theta)^{14}$

- $\text{Argmax}_{\theta} \pi(\theta|\mathbf{x}) = \text{Argmax}_{\theta} L(\mathbf{x}, \theta)\pi(\theta)$
$$= \text{Argmax}_{\theta} [(1-\theta)^{28}\theta^7] \times [(1-\theta)^{14}\theta]$$
$$= \text{Argmax}_{\theta} (1-\theta)^{42}\theta^8$$
$$= \text{Argmax}_{\theta} 42 \ln(1-\theta) + 8 \ln \theta$$

$$\implies \theta_{MAP} = 0,16$$