


MAPSI — cours 4 : Expectation-Maximization (EM)

Christophe Gonzales

LIP6 – Université Paris 6, France

Motivations : Système de recommandation



- Armelle, Bernard, Claude
 $\Rightarrow$ notes films (r_A, r_B, r_C)
- Problème : quel film conseiller à Damien ?
- Solution : échantillons
 $\langle r_A, r_B, r_C, r_D \rangle \Rightarrow P(r_A, r_B, r_C, r_D)$
- conseiller Damien en exploitant
 $P(r_D | r_A, r_B, r_C)$

Cours 3 : détermination de $P(r_A, r_B, r_C, r_D)$ par maximum de vraisemblance ou MAP

Motivations : Système de recommandation

Film	r_A	r_B	r_C	r_D
I robot	4	2	3	3
Forest Gump	1	3	2	4
Intouchables	2	2	3	2
Le parrain	1	3	2	1
Pulp fiction	2	4	3	4

- évaluations : 1, 2, 3, 4
- $P(r_D | r_A, r_B, r_C)$: distribution multivariée
- Θ = paramètres de $P(r_D | r_A, r_B, r_C) \Rightarrow 4^4 = 256$ paramètres θ_i
- $\sum_{r_D} P(r_D | r_A, r_B, r_C) = 1 \Rightarrow 3 \times 4^3 = 192 \theta_i$

Motivations : Système de recommandation

- Vraisemblance : $L(\mathbf{x}, \Theta) = \prod_{\text{film}} \theta_{\text{film}}$
- θ_{abcd} : paramètre pour un film ayant obtenu $(r_A = a, r_B = b, r_C = c, r_D = d)$
- N_{abcd} : nombre de films ayant obtenu $(r_A = a, r_B = b, r_C = c, r_D = d)$
- $$L(\mathbf{x}, \Theta) = \prod_{a=1}^4 \prod_{b=1}^4 \prod_{c=1}^4 \left[\left(1 - \sum_{d=1}^3 \theta_{abcd} \right)^{N_{abc4}} \prod_{d=1}^3 \theta_{abcd}^{N_{abcd}} \right]$$
- $$\log L(\mathbf{x}, \Theta) = \sum_{a=1}^4 \sum_{b=1}^4 \sum_{c=1}^4 \left[N_{abc4} \log \left(1 - \sum_{d=1}^3 \theta_{abcd} \right) + \sum_{d=1}^3 N_{abcd} \log \theta_{abcd} \right]$$
- $$\frac{\partial \log L(\mathbf{x}, \Theta)}{\partial \theta_{abcd}} = - \frac{N_{abc4}}{1 - \sum_{d'=1}^3 \theta_{abcd'}} + \frac{N_{abcd}}{\theta_{abcd}} = 0 \quad \forall d \in \{1, 2, 3\}$$
- $$-N_{abc4} \theta_{abcd} + N_{abcd} \left(1 - \sum_{d'=1}^3 \theta_{abcd'} \right) = 0 \quad \forall d \in \{1, 2, 3\}$$

Motivations : Système de recommandation

- $-N_{abc4}\theta_{abcd} + N_{abcd} \left(1 - \sum_{d'=1}^3 \theta_{abcd'}\right) = 0 \quad \forall d \in \{1, 2, 3\}$

- $\frac{N_{abc4}}{N_{abcd}}\theta_{abcd} + \sum_{d'=1}^3 \theta_{abcd'} = 1 \quad \forall d \in \{1, 2, 3\}$

- $$\begin{bmatrix} 1 + \frac{N_{abc4}}{N_{abc1}} & 1 & 1 \\ 1 & 1 + \frac{N_{abc4}}{N_{abc2}} & 1 \\ 1 & 1 & 1 + \frac{N_{abc4}}{N_{abc3}} \end{bmatrix} \begin{bmatrix} \theta_{abc1} \\ \theta_{abc2} \\ \theta_{abc3} \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

$$\theta_{abcd} = \frac{N_{abcd}}{\sum_{d'=1}^4 N_{abcd'}}$$


Motivations : Système de recommandation

Film	r_A	r_B	r_C	r_D
I robot	4	2	3	3
Forest Gump	1	3	2	4
Intouchables	2	2	3	2
Le parrain	1	3	2	1
Pulp fiction	2	4	3	4


- $\sum_{r_D} P(r_D | r_A, r_B, r_C) = 1 \Rightarrow 3 \times 4^3 = 192 \theta_i$
- probabilités $\Rightarrow$ au moins 2000 évaluations
- certains films n'ont pas été vus $\Rightarrow$ données manquantes

Problème : comment estimer $P(r_D | r_A, r_B, r_C)$?

Motivations : reconstruction de génotypes



Motivations : reconstruction de génotypes



Motivations : reconstruction de génotypes

Génotype, phénotype

Génotype = paire d'allèles d'un segment d'ADN.

Phénotype = caractère observable d'un génotype.

Exemple : groupe sanguin (allèles A, B, O)

génotype	phénotype	X	Y
AA	A	1	1
AB	AB	2	3
AO	A	3	1
BB	B	4	2
BO	B	5	2
OO	O	6	4



6 génotypes mais seulement 4 phénotypes !

Problème : Apprendre en présence de variables latentes

Motivations : tracking avec occlusions



Motivations : résumé

Problèmes étudiés dans ce cours :

- 1 estimation de paramètres en présence de données manquantes
- 2 estimation de paramètres en présence de variables latentes

Solution : l'algorithme EM

Plan du cours n°4

- 1 Principes d'apprentissage avec données manquantes
- 2 Quelques rappels de maths
- 3 L'algorithme EM
- 4 Pourquoi fonctionne-t-il ?
- 5 Mixtures de Gaussiennes et EM

Apprentissage avec données manquantes : principes

X	Y
a	?
a	?
a	?
a	?
a	c
a	c
a	c
a	d
b	c
b	c
b	d
b	d

Algorithme naïf :

- Supprimer les enregistrements avec ?

X	Y
a	c
a	c
a	c
a	d
b	c
b	c
b	d
b	d

- Données complètes
- Apprentissage : cf. cours précédents
- **Problème :**
Tableau gauche : $P(X = a) = 2/3$
Tableau droit : $P(X = a) = 1/2$

⇒ essayer de tenir compte de tous les enregistrements

Apprentissage avec données manquantes : principes

Algorithme k-means :

- Remplacer les ? par leur valeur la plus probable

X	Y
a	?
a	?
a	?
a	?
a	c
a	c
a	c
a	d
a	d
b	c
b	c
b	d
b	d

X	Y
a	c
a	c
a	c
a	c
a	c
a	c
a	d
a	d
b	c
b	c
b	d
b	d

- Données complètes
- Apprentissage : cf. cours précédents
- **Problème :**
Tableau gauche : $P(Y = c|X = a) = 3/4$
(sur les données observées)
Tableau droit : $P(Y = c|X = a) = 7/8$

⇒ essayer de tenir compte de toutes les valeurs possibles de Y

Apprentissage avec données manquantes : principes

Algorithme naïf 2 :

- Remplacer les ? par toutes les valeurs possibles

X	Y
a	?
a	?
a	?
a	?
a	c
a	c
a	c
a	c
a	d
a	d
b	c
b	c
b	d
b	d

X	Y
a	c
a	d
a	c
a	d
a	c
a	d
a	c
a	d
a	c
a	d
b	c
b	d
b	c
b	d

X	Y
a	c
a	c
a	c
a	d
a	c
a	d
a	c
a	d
a	c
a	d
b	c
b	c
b	d
b	d

- Problèmes :**
- Tableau gauche : $P(X = a) = 2/3$
 - Tableau droit : $P(X = a) = 3/4$
 - Tableau gauche : $P(Y = c|X = a) = 3/4$
 - Tableau droit : $P(Y = c|X = a) = 7/12$

⇒ essayer de tenir compte des distributions des valeurs

Apprentissage avec données manquantes : principes

Algorithme EM :

- Remplacer les ? par toutes les valeurs possibles pondérées par leur probabilité d'apparition

X	Y
a	?
a	?
a	?
a	?
a	c
a	c
a	c
a	c
a	d
a	d
b	c
b	c
b	d
b	d

X	Y	w
a	c	3/4
a	d	1/4
a	c	3/4
a	d	1/4
a	c	3/4
a	d	1/4
a	c	3/4
a	d	1/4
a	c	3/4
a	d	1/4
b	c	3/4
b	c	3/4
b	d	1/4
b	d	1/4

X	Y	w
a	c	1
a	c	1
a	c	1
a	d	1
a	d	1
b	c	1
b	c	1
b	d	1
b	d	1

- Apprentissage ⇒ comptages
- ⇒ **sommer les poids**
- ⇒ $P(X = a) = \frac{8}{12} = \frac{2}{3}$
- ⇒ $P(Y = c|X = a) = \frac{6}{8} = \frac{3}{4}$
- ⇒ Tableau gauche = droit

Apprentissage avec données manquantes : principes

- K-means : remplacer ? par la valeur la plus probable
 - EM : Remplacer ? par toutes les valeurs possibles pondérées par leur probabilité d'apparition
- ⇒ On connaît la probabilité des valeurs de $Y|X$
- ⇒ On a un modèle probabiliste de ces valeurs
- Or, c'est justement le modèle qu'on souhaite apprendre !

Idée clef de K-means et EM : algos itératifs

- 1 se donner un modèle initial (pas trop mauvais)
- 2 ce modèle ⇒ données complètes
- 3 apprendre nouveau modèle avec ces données
- 4 revenir en 2 avec nouveau modèle si ≠ ancien modèle

2 Rappels de maths


Apprentissage avec données manquantes : principes

Problèmes :

- 1 Y a-t-il convergence ?
- 1 À convergence, est-ce que l'on a obtenu un bon modèle ?

But du reste du cours 4 : répondre à ces questions pour EM

Rappel : fonctions convexes



Définition

f convexe $\iff \forall \lambda \in [0, 1], \forall x_1, x_2 :$
 $f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2)$

fonction concave

f concave $\iff -f$ convexe

Généralisation : l'inégalité de Jensen

Inégalité de Jensen

- f convexe définie sur D
- $x_1, \dots, x_n \in D$
- $\lambda_1, \dots, \lambda_n \geq 0, \quad \sum_{i=1}^n \lambda_i = 1$

Alors :

$$f\left(\sum_{i=1}^n \lambda_i x_i\right) \leq \sum_{i=1}^n \lambda_i f(x_i)$$

Inégalité de Jensen

- f convexe
- X : variable aléatoire à n dimensions $x_1, \dots, x_n$
- $\lambda_1, \dots, \lambda_n \geq 0, \quad \sum_{i=1}^n \lambda_i = 1 \implies$ probabilité P_λ
- $f(\mathbb{E}_{P_\lambda}(X)) \leq \mathbb{E}_{P_\lambda}(f(X))$ où $\mathbb{E}_{P_\lambda}$ = espérance

Démonstration de l'inégalité de Jensen

$$f\left(\sum_{i=1}^n \lambda_i x_i\right) \leq \sum_{i=1}^n \lambda_i f(x_i)$$

- par récurrence : si $n = 1$: trivial, si $n = 2$: convexité


$$\begin{aligned} \bullet f\left(\sum_{i=1}^{n+1} \lambda_i x_i\right) &= f\left(\lambda_{n+1} x_{n+1} + \sum_{i=1}^n \lambda_i x_i\right) \\ &= f\left(\lambda_{n+1} x_{n+1} + (1 - \lambda_{n+1}) \sum_{i=1}^n \frac{\lambda_i}{1 - \lambda_{n+1}} x_i\right) \\ &\leq \lambda_{n+1} f(x_{n+1}) + (1 - \lambda_{n+1}) f\left(\sum_{i=1}^n \frac{\lambda_i}{1 - \lambda_{n+1}} x_i\right) \\ &\leq \lambda_{n+1} f(x_{n+1}) + (1 - \lambda_{n+1}) \sum_{i=1}^n \frac{\lambda_i}{1 - \lambda_{n+1}} f(x_i) \\ &= \lambda_{n+1} f(x_{n+1}) + \sum_{i=1}^n \lambda_i f(x_i) = \sum_{i=1}^{n+1} \lambda_i f(x_i) \end{aligned}$$

Conséquences de l'inégalité de Jensen

Inégalité de Jensen pour le logarithme

Logarithme = fonction concave :

$$\log\left(\sum_{i=1}^n \lambda_i x_i\right) \geq \sum_{i=1}^n \lambda_i \log(x_i)$$



$$\mathbb{E}(\log(X)) = \log(\mathbb{E}(X)) \implies X = \mathbb{E}(X) = \text{constante}$$

3 L'algorithme EM

Typologies de données incomplètes

- $\mathbf{x}^o$: données observées, $\mathbf{x}^h$: données manquantes
- $\mathbf{x} = \mathbf{x}^o \cup \mathbf{x}^h$

Film	r_A	r_B	r_C	r_D
I robot	4	?	3	3
Forest Gump	?	?	2	4
Intouchables	2	2	3	?
Le parrain	1	?	2	?
Pulp fiction	2	4	3	4

- $\mathcal{M}_{ij} = P(r_i^j \in \mathbf{x}^h)$: position des données manquantes

Typologies de données incomplètes

Typologies

- **Missing Completely at Random (MCAR)** : $P(\mathcal{M}|\mathbf{x}) = P(\mathcal{M})$
Aucune relation entre le fait qu'une donnée soit manquante ou observée
- **Missing at Random (MAR)** : $P(\mathcal{M}|\mathbf{x}) = P(\mathcal{M}|\mathbf{x}^o)$ données manquantes en relation avec les données observées mais pas avec les autres données manquantes
- **Not Missing At Random (NMAR)** : $P(\mathcal{M}|\mathbf{x})$ données manquantes en relation avec *toutes* les données



On n'étudiera que MCAR !

Log-vraisemblance et données incomplètes

- Échantillon $\mathbf{x} = \{x_1, \dots, x_n\}$ de taille n
- données complètes : $\log L(\mathbf{x}, \Theta) = \sum_{i=1}^n \log P(x_i|\Theta)$
- $\mathbf{x}^o$: données observées, $\mathbf{x}^h$: données manquantes
- $\log L(\mathbf{x}^o, \Theta)$ = log-vraisemblance des données observées

$$= \sum_{i=1}^n \log P(x_i^o|\Theta) = \sum_{i=1}^n \log \left(\sum_{\mathbf{x}_i^h \in \mathbf{x}^h} P(x_i^o, \mathbf{x}_i^h|\Theta) \right)$$
- Soit $Q_i(\mathbf{x}_i^h)$ une loi de proba **quelconque** alors :

$$\log L(\mathbf{x}^o, \Theta) = \sum_{i=1}^n \log \left(\sum_{\mathbf{x}_i^h \in \mathbf{x}^h} Q_i(\mathbf{x}_i^h) \frac{P(x_i^o, \mathbf{x}_i^h|\Theta)}{Q_i(\mathbf{x}_i^h)} \right)$$

Log-vraisemblance et données incomplètes

$$\bullet \log L(\mathbf{x}^o, \Theta) = \sum_{i=1}^n \log \left(\sum_{\mathbf{x}_i^h \in \mathbf{x}^h} Q_i(\mathbf{x}_i^h) \frac{P(x_i^o, \mathbf{x}_i^h|\Theta)}{Q_i(\mathbf{x}_i^h)} \right)$$



inégalité de Jensen $\implies \log \left(\sum_{i=1}^n \lambda_i y_i \right) \geq \sum_{i=1}^n \lambda_i \log(y_i)$

$$\log L(\mathbf{x}^o, \Theta) \geq \sum_{i=1}^n \sum_{\mathbf{x}_i^h \in \mathbf{x}^h} Q_i(\mathbf{x}_i^h) \log \left(\frac{P(x_i^o, \mathbf{x}_i^h|\Theta)}{Q_i(\mathbf{x}_i^h)} \right)$$



Jensen $\implies$ égalité ssi $\frac{P(x_i^o, \mathbf{x}_i^h|\Theta)}{Q_i(\mathbf{x}_i^h)} = \text{constante}$

choisir $Q_i(\mathbf{x}_i^h) \propto P(x_i^o, \mathbf{x}_i^h|\Theta) \implies Q_i(\mathbf{x}_i^h) = P(\mathbf{x}_i^h|x_i^o, \Theta)$

Algorithme EM

Algorithme

- 1 choisir une valeur initiale $\Theta = \Theta^0$
- 2 **Étape E (expectation) :**
 - $Q_i^{t+1}(x_i^h) \leftarrow P(x_i^h | x_i^o, \Theta^t) \quad \forall i \in \{1, \dots, n\}$
 - $\log L^{t+1}(\mathbf{x}^o, \Theta) = \sum_{i=1}^n \sum_{x_i^h \in \mathbf{x}^h} Q_i^{t+1}(x_i^h) \log \left(\frac{P(x_i^o, x_i^h | \Theta)}{Q_i^{t+1}(x_i^h)} \right)$
- 3 **Étape M (maximization) :**
 - $\Theta^{t+1} \leftarrow \text{Argmax}_{\Theta} \log L^{t+1}(\mathbf{x}^o, \Theta)$
- 4 Tant qu'on n'a pas convergé, revenir en 2

À convergence, Θ^{t+1} = optimum local par max de vraisemblance

Algorithme EM : un exemple

- 2 variables aléatoires $A \in \{a, b\}$ et $C \in \{c, d\}$

$$P(A, C | \Theta) = \begin{bmatrix} \theta_{ac} & \theta_{ad} \\ \theta_{bc} & \theta_{bd} \end{bmatrix} \Rightarrow \Theta = \{\theta_{ac}, \theta_{ad}, \theta_{bc}, \theta_{bd}\}$$

but : estimer Θ par EM

A	C
a	?
b	?
a	d
b	d
a	c

- A toujours observé :

$$\Rightarrow \theta_{ac} + \theta_{ad} = \frac{3}{5} \text{ par max de vraisemblance}$$

$$\theta_{bc} + \theta_{bd} = \frac{2}{5} \text{ par max de vraisemblance}$$

- initialisation possible :

$$\Theta^0 = \{\theta_{ac}^0 = 0.3, \theta_{ad}^0 = 0.3, \theta_{bc}^0 = 0.2, \theta_{bd}^0 = 0.2\}$$

- **Étape E (expectation) :** $Q_i^1(x_i^h) \leftarrow P(x_i^h | x_i^o, \Theta^0) \quad \forall i \in \{1, 2\}$

$$Q_1^1(C) = P(C | A = a, \Theta^0) = \frac{P(A=a, C | \Theta^0)}{\sum_c P(A=a, C | \Theta^0)} = \left[\frac{0.3}{0.6}, \frac{0.3}{0.6} \right] = [0.5, 0.5]$$

$$Q_2^1(C) = P(C | A = b, \Theta^0) = \frac{P(A=b, C | \Theta^0)}{\sum_c P(A=b, C | \Theta^0)} = \left[\frac{0.2}{0.4}, \frac{0.2}{0.4} \right] = [0.5, 0.5]$$

Algorithme EM : un exemple

$$\Theta^0 = \{\theta_{ac}^0 = 0.3, \theta_{ad}^0 = 0.3, \theta_{bc}^0 = 0.2, \theta_{bd}^0 = 0.2\}$$

$$Q_1^1(C) = [0.5, 0.5] \quad Q_2^1(C) = [0.5, 0.5] \quad P(x_i^h, x_i^o | \Theta^0) = \begin{bmatrix} 0.3 & 0.3 \\ 0.2 & 0.2 \end{bmatrix}$$

$$\log L^{t+1}(\mathbf{x}^o, \Theta) = \sum_{i=1}^n \sum_{x_i^h \in \mathbf{x}^h} Q_i^{t+1}(x_i^h) \log \left(\frac{P(x_i^o, x_i^h | \Theta)}{Q_i^{t+1}(x_i^h)} \right)$$

A	B	Q_i^{t+1}	P/Q_i^{t+1}	$\log(P/Q_i^{t+1})$
a	c	0.5	$\theta_{ac}/0.5$	$\log \theta_{ac} - \log 0.5$
a	d	0.5	$\theta_{ad}/0.5$	$\log \theta_{ad} - \log 0.5$
b	c	0.5	$\theta_{bc}/0.5$	$\log \theta_{bc} - \log 0.5$
b	d	0.5	$\theta_{bd}/0.5$	$\log \theta_{bd} - \log 0.5$
a	d	1	θ_{ad}	$\log \theta_{ad}$
b	d	1	θ_{bd}	$\log \theta_{bd}$
a	c	1	θ_{ac}	$\log \theta_{ac}$



$\Rightarrow$ revient à observer l'échantillon avec poids Q_i^{t+1}

Algorithme EM

$$\begin{aligned} \log L^{t+1}(\mathbf{x}^o, \Theta) &= \sum_{i=1}^n \sum_{x_i^h \in \mathbf{x}^h} Q_i^{t+1}(x_i^h) \log \left(\frac{P(x_i^o, x_i^h | \Theta)}{Q_i^{t+1}(x_i^h)} \right) \\ &= \sum_{i=1}^n \sum_{x_i^h \in \mathbf{x}^h} Q_i^{t+1}(x_i^h) \left[\log(P(x_i^o, x_i^h | \Theta)) - \log(Q_i^{t+1}(x_i^h)) \right] \end{aligned}$$

$$\Rightarrow \Theta^{t+1} = \text{Argmax}_{\Theta} \log L^{t+1}(\mathbf{x}^o, \Theta)$$

$$= \text{Argmax}_{\Theta} \sum_{i=1}^n \sum_{x_i^h \in \mathbf{x}^h} Q_i^{t+1}(x_i^h) \log(P(x_i^o, x_i^h | \Theta))$$

Principe de EM

Étape M $\Rightarrow$ maximum de vraisemblance avec un échantillon dont chaque enregistrement x_i a un poids Q_i^{t+1}

Algorithme EM : un exemple

$$\Theta^1 = \operatorname{Argmax}_{\Theta} \sum_{i=1}^n \sum_{x_i^h \in \mathbf{x}^h} Q_i^{t+1}(x_i^h) \log \left(\frac{P(x_i^o, x_i^h | \Theta)}{Q_i^{t+1}(x_i^h)} \right)$$

A	B	Q_i^{t+1}	$\log \theta$
a	c	0.5	$\log \theta_{ac}$
a	d	0.5	$\log \theta_{ad}$
b	c	0.5	$\log \theta_{bc}$
b	d	0.5	$\log \theta_{bd}$
a	d	1	$\log \theta_{ad}$
b	d	1	$\log \theta_{bd}$
a	c	1	$\log \theta_{ac}$

$$\Theta^1 = \operatorname{Argmax}_{\Theta} [0.5 + 1] \log \theta_{ac} + [0.5 + 1] \log \theta_{ad} + 0.5 \log \theta_{bc} + [0.5 + 1] \log \theta_{bd}$$

Sous contrainte : $\theta_{ac} + \theta_{ad} + \theta_{bc} + \theta_{bd} = 1$

$$\Theta^1 = \{\theta_{ac}^1 = \frac{3}{10}, \theta_{ad}^1 = \frac{3}{10}, \theta_{bc}^1 = \frac{1}{10}, \theta_{bd}^1 = \frac{3}{10}\}$$

Algorithme EM : un exemple

$$\Theta^1 = \{\theta_{ac}^1 = \frac{3}{10}, \theta_{ad}^1 = \frac{3}{10}, \theta_{bc}^1 = \frac{1}{10}, \theta_{bd}^1 = \frac{3}{10}\}$$

A	C
a	?
b	?
a	d
b	d
a	c

- Étape E (expectation) : $Q_i^2(x_i^h) \leftarrow P(x_i^h | x_i^o, \Theta^1) \quad \forall i \in \{1, 2\}$

$$Q_1^2(C) = P(C | A = a, \Theta^1) = \frac{P(A=a, C | \Theta^1)}{\sum_c P(A=a, C | \Theta^1)} = \left[\frac{0.3}{0.6}, \frac{0.3}{0.6} \right] = [0.5, 0.5]$$

$$Q_2^2(C) = P(C | A = b, \Theta^1) = \frac{P(A=b, C | \Theta^1)}{\sum_c P(A=b, C | \Theta^1)} = \left[\frac{0.1}{0.4}, \frac{0.3}{0.4} \right] = [0.25, 0.75]$$

Algorithme EM : un exemple

$$\Theta^1 = \{\theta_{ac}^1 = \frac{3}{10}, \theta_{ad}^1 = \frac{3}{10}, \theta_{bc}^1 = \frac{1}{10}, \theta_{bd}^1 = \frac{3}{10}\}$$

$$Q_1^2(C) = [0.5, 0.5] \quad Q_2^2(C) = [0.25, 0.75] \quad P(x_i^h, x_i^o | \Theta^0) = \begin{bmatrix} 0.3 & 0.3 \\ 0.1 & 0.3 \end{bmatrix}$$

$$\log L^{t+1}(\mathbf{x}^o, \Theta) = \sum_{i=1}^n \sum_{x_i^h \in \mathbf{x}^h} Q_i^{t+1}(x_i^h) \log \left(\frac{P(x_i^o, x_i^h | \Theta)}{Q_i^{t+1}(x_i^h)} \right)$$

A	B	Q_i^{t+1}	P/Q_i^{t+1}	$\log(P/Q_i^{t+1})$
a	c	0.5	$\theta_{ac}/0.5$	$\log \theta_{ac} - \log 0.5$
a	d	0.5	$\theta_{ad}/0.5$	$\log \theta_{ad} - \log 0.5$
b	c	0.25	$\theta_{bc}/0.25$	$\log \theta_{bc} - \log 0.25$
b	d	0.75	$\theta_{bd}/0.75$	$\log \theta_{bd} - \log 0.75$
a	d	1	θ_{ad}	$\log \theta_{ad}$
b	d	1	θ_{bd}	$\log \theta_{bd}$
a	c	1	θ_{ac}	$\log \theta_{ac}$

$$\Theta^2 = \operatorname{Argmax}_{\Theta} [0.5 + 1] \log \theta_{ac} + [0.5 + 1] \log \theta_{ad} + 0.25 \log \theta_{bc} + [0.75 + 1] \log \theta_{bd}$$

Sous contrainte : $\theta_{ac} + \theta_{ad} + \theta_{bc} + \theta_{bd} = 1$

Algorithme EM : un exemple

$$\Theta^2 = \{\theta_{ac}^2 = \frac{3}{10}, \theta_{ad}^2 = \frac{3}{10}, \theta_{bc}^2 = \frac{1}{20}, \theta_{bd}^2 = \frac{7}{20}\}$$

$$\Theta^3 = \{\theta_{ac}^3 = \frac{3}{10}, \theta_{ad}^3 = \frac{3}{10}, \theta_{bc}^3 = \frac{1}{40}, \theta_{bd}^3 = \frac{15}{40}\}$$

...

$$\bullet \theta_{ac} = \theta_{bc} = 0, 3$$

$$\bullet \theta_{bc} + \theta_{bd} = 0, 4 \text{ et } \theta_{bc} \text{ divisé par 2 à chaque étape.}$$

$$\Rightarrow \text{à convergence :}$$

$$\Theta = \{\theta_{ac} = \frac{3}{10}, \theta_{ad} = \frac{3}{10}, \theta_{bc} = 0, \theta_{bd} = \frac{4}{10}\}$$

Film	r_A	r_B	r_C	r_D		
I robot	4	?	3	3	$\leftarrow Q_1^{t+1}(r_B)$	$\Rightarrow 4$ enregistrements
Forest Gump	?	?	2	4	$\leftarrow Q_2^{t+1}(r_A, r_B)$	$\Rightarrow 16$ enregistrements
Intouchables	2	2	3	?	$\leftarrow Q_3^{t+1}(r_D)$	$\Rightarrow 4$ enregistrements
Le parrain	1	?	2	?	$\leftarrow Q_4^{t+1}(r_B, r_D)$	$\Rightarrow 16$ enregistrements
Pulp fiction	2	4	3	4	$\leftarrow Q_5^{t+1}() = 1$	$\Rightarrow 1$ enregistrement

$\Rightarrow 4 + 16 + 4 + 16 + 1 = 41$ enregistrements pour calculer Θ^{t+1}

4 Pourquoi EM fonctionne-t-il ?

Rappel : Algorithme EM

Algorithme

- 1 choisir une valeur initiale $\Theta = \Theta^0$
- 2 **Étape E (expectation) :**
 - $Q_i^{t+1}(x_i^h) \leftarrow P(x_i^h | x_i^o, \Theta^t) \quad \forall i \in \{1, \dots, n\}$
 - $\log L^{t+1}(\mathbf{x}^o, \Theta) = \sum_{i=1}^n \sum_{x_i^h \in \mathbf{x}^h} Q_i^{t+1}(x_i^h) \log \left(\frac{P(x_i^o, x_i^h | \Theta)}{Q_i^{t+1}(x_i^h)} \right)$
- 3 **Étape M (maximization) :**
 - $\Theta^{t+1} \leftarrow \text{Argmax}_{\Theta} \log L^{t+1}(\mathbf{x}^o, \Theta)$
- 4 Tant qu'on n'a pas convergé, revenir en 2

Convergence de EM : monotonie

Étape E : $\log L^{t+1}(\mathbf{x}^o, \Theta) = \sum_{i=1}^n \sum_{x_i^h \in \mathbf{x}^h} Q_i^{t+1}(x_i^h) \log \left(\frac{P(x_i^o, x_i^h | \Theta)}{Q_i^{t+1}(x_i^h)} \right)$

Étape M : $\Theta^{t+1} \leftarrow \text{Argmax}_{\Theta} \log L^{t+1}(\mathbf{x}^o, \Theta)$

$\Rightarrow \log L^{t+1}(\mathbf{x}^o, \Theta^{t+1}) \geq \log L^{t+1}(\mathbf{x}^o, \Theta^t)$

Rappel : inégalité de Jensen

$\forall$ loi de proba $Q_i(x_i^h)$:

$$\log L(\mathbf{x}^o, \Theta^t) \geq \sum_{i=1}^n \sum_{x_i^h \in \mathbf{x}^h} Q_i(x_i^h) \log \left(\frac{P(x_i^o, x_i^h | \Theta^t)}{Q_i(x_i^h)} \right)$$

égalité $\Leftrightarrow Q_i(x_i^h) = P(x_i^h | x_i^o, \Theta^t) = Q_i^{t+1}(x_i^h)$

$\Rightarrow \begin{cases} \log L^{t+1}(\mathbf{x}^o, \Theta^t) = \log L(\mathbf{x}^o, \Theta^t) \geq \log L^t(\mathbf{x}^o, \Theta^t) \\ \log L(\mathbf{x}^o, \Theta^{t+1}) \geq \log L^{t+1}(\mathbf{x}^o, \Theta^{t+1}) \end{cases}$

$\Rightarrow L(\mathbf{x}^o, \Theta^{t+1}) \geq L^{t+1}(\mathbf{x}^o, \Theta^{t+1}) \geq L(\mathbf{x}^o, \Theta^t) \geq L^t(\mathbf{x}^o, \Theta^t)$

$$L(\mathbf{x}^o, \Theta^{t+1}) \geq L^{t+1}(\mathbf{x}^o, \Theta^{t+1}) \geq L(\mathbf{x}^o, \Theta^t) \geq L^t(\mathbf{x}^o, \Theta^t)$$

Propriété de EM

EM converge vers un maximum local de la vraisemblance




si $\text{Argmax}_{\Theta} L^{t+1}(\mathbf{x}^o, \Theta)$ estimé par descente de gradient, on peut perdre cette propriété !

5 Mixture de Gaussiennes et EM

Mixture de gaussiennes

$$p(\cdot) = 0,3 \times \mathcal{N}(0, 2^2) + 0,4 \times \mathcal{N}(4, 3^2) + 0,3 \times \mathcal{N}(-3, 1^2)$$



Application : apprentissage de prix fonciers

postulat : prix de biens similaires dans un quartier $\sim$ identiques

$\Rightarrow$ prix dépendent $\left\{ \begin{array}{l} \text{des caractéristiques du bien (e.g. nombre de pièces)} \\ \text{du quartier} \end{array} \right.$

$\Rightarrow$ modélisation par une mixture de gaussiennes (ici 2 gaussiennes)

Modélisation du problème

- $\Theta = \{\mu_1, \mu_2, \sigma_1, \sigma_2, \pi_1, \pi_2\}$
- $p(x|\Theta) = \pi_1 \mathcal{N}(\mu_1, \sigma_1^2) + \pi_2 \mathcal{N}(\mu_2, \sigma_2^2)$

Apprentissage non supervisé

- échantillon $\mathbf{x} = \langle x_1, \dots, x_n \rangle$
- $x_i = \text{prix} \Rightarrow$ on ne connaît pas la Gaussienne à laquelle le bien appartient



échantillon supposé complet (pas de données manquantes)

Application : apprentissage de prix fonciers

échantillon complet $\Rightarrow$ estimation par max de vraisemblance

$$L(\mathbf{x}, \Theta) = \prod_{i=1}^n p(x_i | \Theta) = \prod_{i=1}^n \sum_{k=1}^2 \pi_k \frac{1}{\sqrt{2\pi}\sigma_k} \exp \left\{ -\frac{1}{2} \left(\frac{x_i - \mu_k}{\sigma_k} \right)^2 \right\}$$

$$\log L(\mathbf{x}, \Theta) = \sum_{i=1}^n \log \left[\sum_{k=1}^2 \pi_k \frac{1}{\sqrt{2\pi}\sigma_k} \exp \left\{ -\frac{1}{2} \left(\frac{x_i - \mu_k}{\sigma_k} \right)^2 \right\} \right]$$

⚠ trop compliqué à maximiser analytiquement !

Solution : EM

- 1 x_i appartient à une classe $y_{k(i)}$ non observée $\sim \mathcal{N}(\mu_{k(i)}, \sigma_{k(i)})$
- 2 échantillon $\mathbf{x} = \langle (x_i, y_{k(i)}) \rangle$
- 3 échantillon maintenant avec données manquantes $\Rightarrow$ EM

Application : apprentissage de prix fonciers

Nouvelle modélisation du problème

$$p(X_i, Y_{k(i)} | \Theta) = p(X_i | Y_{k(i)}, \Theta) P(Y_{k(i)} | \Theta) = \begin{bmatrix} \mathcal{N}(\mu_1, \sigma_1^2) \pi_1 \\ \mathcal{N}(\mu_2, \sigma_2^2) \pi_2 \end{bmatrix}$$

$\Rightarrow$ pour x_i connu :

$$P(Y_{k(i)} | x_i, \Theta) = \frac{p(x_i, Y_{k(i)} | \Theta)}{p(x_i | \Theta)} \propto \begin{bmatrix} \frac{1}{\sqrt{2\pi}\sigma_1} \exp \left\{ -\frac{1}{2} \left(\frac{x_i - \mu_1}{\sigma_1} \right)^2 \right\} \times \pi_1 \\ \frac{1}{\sqrt{2\pi}\sigma_2} \exp \left\{ -\frac{1}{2} \left(\frac{x_i - \mu_2}{\sigma_2} \right)^2 \right\} \times \pi_2 \end{bmatrix}$$

• Initialisation d'EM : choisir une valeur $\Theta^0 = \{\mu_1^0, \mu_2^0, \sigma_1^0, \sigma_2^0, \pi_1^0, \pi_2^0\}$

• Étape E : $Q_i^1(y_k) \leftarrow P(y_k | x_i, \Theta^0)$ pour $k = 1, 2$
 $\Rightarrow Q_i^1(\cdot)$ très facile à calculer

• Étape M :

$$\text{Argmax}_{\Theta} \log L^{t+1}(\mathbf{x}^0, \Theta) = \text{Argmax}_{\Theta} \sum_{i=1}^n \sum_{k=1}^2 Q_i^{t+1}(y_k) \log \left(\frac{p(x_i, y_k | \Theta)}{Q_i^{t+1}(y_k)} \right)$$

Application : apprentissage de prix fonciers

Étape M :

$$\begin{aligned} & \text{Argmax}_{\Theta} \log L^{t+1}(\mathbf{x}^0, \Theta) \\ &= \text{Argmax}_{\Theta} \sum_{i=1}^n \sum_{k=1}^2 Q_i^{t+1}(y_k) \log \left(\frac{p(x_i, y_k | \Theta)}{Q_i^{t+1}(y_k)} \right) \\ &= \text{Argmax}_{\Theta} \sum_{i=1}^n Q_i^{t+1}(y_1) \log \left(\pi_1 \frac{1}{\sqrt{2\pi}\sigma_1^2} \exp \left\{ -\frac{1}{2} \left(\frac{x_i - \mu_1}{\sigma_1} \right)^2 \right\} \right) + \\ & \quad Q_i^{t+1}(y_2) \log \left(\pi_2 \frac{1}{\sqrt{2\pi}\sigma_2^2} \exp \left\{ -\frac{1}{2} \left(\frac{x_i - \mu_2}{\sigma_2} \right)^2 \right\} \right) \\ &= \text{Argmax}_{\Theta} \sum_{i=1}^n Q_i^{t+1}(y_1) \left[\log(\pi_1) - \frac{1}{2} \log(\sigma_1^2) - \frac{1}{2} \left(\frac{x_i - \mu_1}{\sigma_1} \right)^2 \right] + \\ & \quad Q_i^{t+1}(y_2) \left[\log(\pi_2) - \frac{1}{2} \log(\sigma_2^2) - \frac{1}{2} \left(\frac{x_i - \mu_2}{\sigma_2} \right)^2 \right] \end{aligned}$$

⚠ Argmax facile à calculer !

classification d'images



Signatures spectrales en teintes de gris

- neige $\sim \mathcal{N}(\mu_1, \sigma_1^2)$
- forêt $\sim \mathcal{N}(\mu_2, \sigma_2^2)$
- désert $\sim \mathcal{N}(\mu_3, \sigma_3^2)$
- mer $\sim \mathcal{N}(\mu_4, \sigma_4^2)$
- Y = observation en teinte de gris = pixels d'une image
- Z = classe paysage $\in \{1, 2, 3, 4\} \sim$ distribution $(\pi_1, \pi_2, \pi_3, \pi_4)$

Paramètres du problème

- $\Theta = \{(\mu_j, \sigma_j^2)\}_{j=1}^4 \cup \{\pi_j\}_{j=1}^4$
- $p(Y, Z|\Theta) = p(Y|Z, \Theta)P(Z|\Theta) = \sum_{j=1}^4 \pi_j \mathcal{N}(\mu_j, \sigma_j^2)$


- Y : observations, Z : classes de paysage
 - $p(Y, Z|\Theta) = \sum_{j=1}^4 \pi_j \mathcal{N}(\mu_j, \sigma_j^2)$
 - base de données incomplète ou Z non observé
- $\Rightarrow$ estimation de Θ par EM (similaire aux prix fonciers)

Le geyser Old Faithful

Geyser du parc national de Yellowstone



Le geyser Old Faithful



- Données : (durée de l'éruption, temps jusqu'à la prochaine éruption)
- $\Rightarrow$ ressemble à une mixture de 2 gaussiennes

[http://en.wikipedia.org/wiki/Expectation-maximization_algorithm]