

Chapitre 1

Statistique descriptive

La **statistique descriptive** est la branche des mathématiques qui consiste à résumer et à illustrer les informations contenues dans des données. Elle se distingue de la **statistique inférentielle** qui consiste à faire des prévisions et à prendre des décisions à partir d'un échantillon de données.

Les deux principaux outils de la statistique descriptive sont :

- la représentation graphique,
- les indicateurs statistiques.

1.1 Données et variables

Les **données** sont des mesures faites sur des individus issus d'une **population**. On décide d'un caractère (**variable**) que l'on mesure sur chaque individu. En général, on ne fait la mesure que sur un sous-ensemble de la population, appelé **échantillon**. Dans ce cas, on parle de **sondage**. Dans le cas où la mesure est faite sur tous les individus de la population, on parle de **recensement**.

Si l'échantillon contient n individus, les résultats de la mesure d'une variable chez chacun d'entre eux est noté $x_1, x_2, \dots, x_n \in E$. On les appelle les **observations**. Elles seront parfois réunies dans un n -uplet $x = (x_1, \dots, x_n) \in E^n$. Pour utiliser la boîte à outils du cours de probabilités, on supposera que chacune de ces mesures x_i est la réalisation d'une variable aléatoire, que l'on note X_i . On supposera souvent que les variables aléatoires X_i sont indépendantes et de même loi. Par commodité de notation, on posera aussi une variable aléatoire X qui suit la même loi.

Exemple 1.1. On peut mesurer la couleur des yeux dans la population française avec un sondage sur $n = 30$ individus. On pose $E = \{\text{Bleu, Vert, Brun, Pers, Noir}\}$. Chaque observation $x_i \in E$ est supposée être la réalisation d'une variable aléatoire X_i à valeur dans E . Il faut faire attention à ce que l'hypothèse d'indépendance soit satisfaite.

Définition 1.2.

- Une variable **discrète** est une variable à valeurs dans un ensemble E fini ou dénombrable.
 - Si $E \subset \mathbb{R}$, la variable est **quantitative** (ou numérique).
 - Lorsqu'une variable exprime l'appartenance à une catégorie, elle est dite **qualitative** (ou catégorielle). Chaque catégorie est appelée **modalité**.
- Une **variable continue** est une variable à valeurs dans un ensemble non dénombrable.

Exemple 1.3. La couleur des yeux est une variable discrète qualitative. Le nombre d'enfants est une variable discrète quantitative. Le taux de cholestérol est une variable continue.

Remarque. Même si la variable est à valeurs dans un ensemble infini, elle n'admettra qu'un nombre fini de réalisations dans un échantillon de taille n . Par exemple, la taille en centimètres est une variable à valeur dans l'ensemble infini $\mathbb{R}$, mais l'ensemble des tailles mesurées dans un échantillon est fini : il s'agit de l'ensemble $\{x_i \in \mathbb{R} \mid i = 1, \dots, n\}$.

1.2 Représentations graphiques

Les données sont souvent très nombreuses. On a donc besoin de résumer l'information qu'elles contiennent. Par exemple, on trouve sur le site de l'INSEE un jeu de données contenant les prénoms attribués aux enfants nés en France depuis 1900. Ce jeu de données contient $n = 6\,454\,981$ individus.

Variables discrètes, qualitatives

Tableau des fréquences

La représentation graphique la plus simple à mettre en œuvre est le **tableau des fréquences absolues** :

Couleur des yeux	Fréquence absolue
Bleu	66
Vert	34
Brun	80
Pers	15
Noir	5

TABLE 1.1 – Couleurs des yeux d'un échantillon de $n = 200$ personnes

Pour réaliser ce tableau, on note $E = \{e_1, \dots, e_k\}$ l'ensemble des modalités de l'échantillon, puis on calcule la **fréquence absolue** n_j de chaque modalité e_j via la formule :

$$n_j = \sum_{i=1}^n \mathbb{1}_{e_j}(x_i).$$

Cette représentation est peu parlante, surtout avec de gros échantillons. Pour l'améliorer, on peut faire un **tableau des fréquences relatives**, où chaque fréquence est exprimée en pourcentage :

Couleur des yeux	Fréquence absolue	Fréquence relative (%)
Bleu	66	33.0
Vert	34	17.0
Brun	80	40.0
Pers	15	7.5
Noir	5	2.5

TABLE 1.2 – Couleurs des yeux d'un échantillon de $n = 200$ personnes

Ici on a calculé la **fréquence relative** de chaque modalité :

$$f_j = \frac{n_j}{n}.$$

Diagrammes

On dispose de deux techniques pour représenter visuellement la même information :

- Le **diagramme en colonnes** (ou **diagramme en bâtons**) : à chaque modalité correspond un rectangle dont la hauteur est proportionnelle à la fréquence de cette modalité. La largeur de chaque colonne est fixe.
- Le **diagramme sectoriel** (ou **camemberts**) : à chaque modalité correspond un secteur de disque dont l'angle est proportionnel à la fréquence de cette modalité.




FIGURE 1.1 – Diagramme en bâtons

Répartition des couleurs des yeux (n = 200)




FIGURE 1.2 – Diagramme sectoriel

Remarque. À quoi ressemble le diagramme en bâtons représentant les fréquences relatives ?

Remarque. Pour une variable qualitative, on préfère souvent ordonner les bâtons par ordre de fréquence. Cette remarque vaut aussi pour les diagrammes en camemberts.

Remarque. Pour réaliser un diagramme en camemberts, on ramène la fréquence de chaque modalité à un **angle** θ_j compris entre 0 et 2π . Cependant, pour lire le même diagramme, on a tendance à comparer les **aires** $\mathcal{A}_j$ des différentes parts du camembert. Ce n'est pas un problème ici car ces deux quantités sont proportionnelles.

Variables discrètes, quantitatives

On peut toujours utiliser les mêmes représentations que celles utilisées pour les variables discrète, qualitatives. Cependant, les modalités sont ici des nombres réels, et possèdent donc un ordre naturel. On privilégiera donc les diagrammes en bâtons, en ordonnant les rectangles selon l'ordre naturel des réels.



FIGURE 1.3 – Les rectangles sont ordonnés

Variables continues

Une variable est continue si elle est à valeurs dans un ensemble non-dénombrable, comme $\mathbb{R}$. Dans ce cas, toutes les mesures de cette variable faite sur une population sont différentes (presque sûrement), et faire un diagramme en bâton est inutile car tous les rectangles seraient de même taille.

Par exemple, si on considère la durée de vie d'un ensemble d'ampoules fabriquées par une usine :

Durée de vie en jours	Fréquence absolue	Fréquence relative (%)
91,6	1	10
35,7	1	10
251,3	1	10
24,3	1	10
5,4	1	10
67,3	1	10
170,9	1	10
9,5	1	10
118,4	1	10
57,1	1	10

TABLE 1.3 – Durée de vie des ampoules. Les fréquences sont inutiles.

Histogrammes

Le principe de l'histogramme est de regrouper les observations qui se ressemblent dans la même classe afin d'obtenir un petit nombre de classes et de pouvoir faire un “diagramme en bâtons amélioré.”

Voici la méthode.

1. On ordonne l'échantillon : on considère l'échantillon $x_1^*, \dots, x_n^*$ constitué des mêmes observations que $x_1, \dots, x_n$ mais tel que $x_i^* \leq x_j^*$ pour tout $i < j$.
2. On se fixe une borne inférieure $a_0 < x_1^*$ de l'échantillon, ainsi qu'une borne supérieure $a_k \geq x_n^*$. Toutes les observations x_i sont donc comprises dans le même intervalle $I =]a_0, a_k]$.
3. On partitionne l'intervalle $I =]a_0, a_k]$ en sous-intervalles $I_j =]a_{j-1}, a_j]$. Chaque intervalle I_j est appelé une **classe**. Il y a k classes différentes. Chaque classe $]a_{j-1}, a_j]$ possède une certaine **largeur** $h_j = a_j - a_{j-1}$. La largeur h_j est la largeur de l'intervalle I_j .
4. On calcule l'**effectif** n_j de chaque classe I_j via la formule

$$n_j = \sum_{i=1}^n \mathbb{1}_{]a_{j-1}, a_j]}(x_i).$$

Puis on calcule la **fréquence** f_j de chaque classe via la formule $f_j = n_j/n$.

5. On réalise l'histogramme selon la définition suivante.

Définition 1.4. L'**histogramme** de l'échantillon est le diagramme en bâtons dont les modalités sont les classes I_j , les largeurs des rectangles sont les largeurs h_j , et les aires sont les fréquences f_j des classes. L'histogramme est à **pas fixe** si toutes les largeurs h_j sont les mêmes. Si les h_j ne sont pas égales, l'histogramme est à **pas variable**. Les hauteurs des différents rectangles sont appelées **densités** d_j et peuvent être calculées via la formule

$$d_j = \frac{f_j}{h_j} = \frac{n_j}{nh_j}.$$

Remarque. La hauteur de chaque rectangle est déterminé par sa largeur et par son aire. Puisqu'on choisit d'utiliser l'aire, un histogramme pour l'échantillon x_i ressemble à la densité de la variable aléatoire X_i , d'où le terme de densité pour décrire la hauteur.

On applique à l'exemple des ampoules.

Échantillon x_i	91,6	35,7	251,3	24,3	5,4	67,3	170,9	9,5	118,4	57,1
Échantillon x_i^*	5,4	9,5	24,3	35,7	57,1	67,3	91,6	118,4	170,9	251,3


TABLE 1.4 – Durée de vie des ampoules, échantillon ordonné.

Choisissons de faire $k = 5$ classes. Prenons $a_0 = 0 < 5,4$ et $a_5 = 260 \geq 251,3$. On choisit un pas fixe en divisant l'intervalle $I =]a_0, a_5]$ en $k = 5$ intervalles identiques. La largeur est donc $h = (260 - 0)/5 = 52$. On obtient le tableau des effectifs suivant.

Classes $]a_j, a_{j+1}]$	$]0; 52]$	$]52; 104]$	$]104; 156]$	$]156; 208]$	$]208; 260]$
Effectifs n_j	4	3	1	1	1
Fréquences n_j/n	40%	30%	10%	10%	10%
Largeurs h_j	52	52	52	52	52
Hauteurs $n_j/(nh)$	0,0077	0,0058	0,0019	0,0019	0,0019

TABLE 1.5 – Durée de vie des ampoules, classes à pas fixe.

L'histogramme correspondant :



On remarque qu'il y a beaucoup d'individus dans la première classe, tandis que les dernières n'en comportent qu'un seul. Il est possible, dans un histogramme à pas fixe, que certaines classes soient vides. Pour équilibrer les effectifs de chaque classe, on peut faire un **histogramme à classes de même effectif** : on choisit le nombre de classes, puis on s'arrange pour que chaque classe contienne le même nombre d'individus.


Pas fixe (52 j.)	5,4	9,5	24,3	35,7	57,1	67,3	91,6	118,4	170,9	251,3
Même effectif (2)	5,4	9,5	24,3	35,7	57,1	67,3	91,6	118,4	170,9	251,3

TABLE 1.6 – Durée de vie des ampoules, classes à pas fixe contre classes à même effectif.

Pour choisir les bornes a_j des différentes classes, on peut prendre le milieu entre deux observations successives. Dans l'exemple des ampoules, cela donne par exemple $a_1 = (9,5 + 24,3)/2 = 16,9$, $a_2 = (35,7 + 57,1)/2 = 46,4$, etc... Les largeurs des classes ne sont pas fixes, et donc les largeurs des rectangles sont aussi variables.

Classes $]a_j, a_{j+1}]$	$]0; 16]$	$]16; 46]$	$]46; 79]$	$]79; 145]$	$]145; 260]$
Effectifs n_j	2	2	2	2	2
Fréquences n_j/n	20%	20%	20%	20%	20%
Largeurs h_j	16	30	33	66	115
Hauteurs $n_j/(nh)$	0,0118	0,0069	0,0061	0,0030	0,0017

TABLE 1.7 – Durée de vie des ampoules, classes à même effectif.



Remarque. Combien de classes doit-on choisir ? À priori, il n'existe pas de réponse absolue à cette question. Pour un échantillon que l'on suppose distribué selon une loi normale, la **règle de Sturges** préconise de prendre $k = 1 + \log_2 n$. De même, il n'y a pas de règle absolue quant au choix des bornes a_0 et a_k .


Remarque. Les deux histogrammes ont été produits avec les mêmes données, mais ne sont pas exactement les mêmes. Ils donnent cependant une idée de la densité derrière la variable aléatoire X supposée produire les observations x_i . Ici par exemple, la loi exponentielle semble être une meilleure candidate que la loi normale par exemple.

Fonction de répartition empirique

Définition 1.5. La **fonction de répartition empirique** F_n associée à l'échantillon $x_1, \dots, x_n$ est la fonction qui associe à tout $x \in \mathbb{R}$ le pourcentage d'observations x_i inférieures ou égales à x :

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{x_i \leq x} = \begin{cases} 0 & \text{si } x < x_1^* \\ \frac{i}{n} & \text{si } x_i^* \leq x < x_{i+1}^* \\ 1 & \text{si } x_n^* \leq x \end{cases}$$

La fonction de répartition F de la variable aléatoire X donne la probabilité que X soit inférieure à x , tandis que la fonction de répartition empirique donne la proportion des observations x_i qui sont inférieures à x . En ce sens, la fonction de répartition empirique de $x_1, \dots, x_n$ est une estimation de la fonction de répartition de X .



Graphe de probabilité

Comment reconnaître la fonction de répartition de X à partir de l'échantillon $x_1, \dots, x_n$? Non seulement les fonctions de répartition se ressemblent toutes (elles sont croissantes, valent 0 à gauche et 1 à droite), mais en plus, les fonctions de répartition empiriques n'en sont qu'une estimation.

Pour faciliter l'estimation à l'œil nu, on utilise un graphe de probabilités. C'est un nuage de points dessiné à partir de la fonction de répartition empirique et d'une hypothèse sur la loi des X_i . Plus les points du graphe de probabilité seront alignés, plus on accordera de crédit à l'hypothèse sur la loi.

Supposons qu'on fasse l'hypothèse que X suit une loi de fonction de répartition F dépendant d'un paramètre θ . L'idée est de trouver une relation linéaire du type

$$h[F(x)] = \alpha(\theta)g(x) + \beta(\theta)$$

où h et g sont des fonctions qui ne dépendent pas de θ .

Ainsi, si la vraie fonction de répartition de X est F , alors $h[F_n(x)]$ est proche de $h[F(x)]$ pour tout x . En particulier, puisque $F_n(x_i^*) = \frac{i}{n}$, alors les points $(g(x_i^*), h(i/n))$ doivent être proches de la droite d'équation $y = \alpha(\theta)x + \beta(\theta)$. On doit donc, à l'œil nu, les voir presque alignés.

De plus, la pente et l'ordonnée à l'origine de la droite déterminent $\alpha(\theta)$ et $\beta(\theta)$ et sont utiles pour estimer le paramètre θ .

Définition 1.6. Soit F la fonction de répartition d'une loi de probabilité, dépendant d'un paramètre inconnu θ . S'il existe des fonctions h , g , α et β telles que

$$\forall x \in \mathbb{R}, \quad h[F(x)] = \alpha(\theta)g(x) + \beta(\theta)$$

alors le nuage de points

$$QQ = \{(g(x_i^*), h(i/n)) \in \mathbb{R}^2 \mid i \in \{1, \dots, n\}\}$$

est appelé **graphe de probabilités** pour la loi de fonction de répartition F (on dit aussi **diagramme quantile-quantile** ou **Q-Q plot**). Si les points du nuage sont approximativement alignés, on admettra que F est une fonction de répartition plausible pour les observations.

Reprenons l'exemple des ampoules.

Hypothèse 1 : la durée de vie d'une ampoule suit une loi exponentielle de paramètre λ . La fonction de répartition de cette loi est

$$F(x) = 1 - e^{-\lambda x}.$$


On en déduit

$$\ln(1 - F(x)) = -\lambda x$$

et on peut donc poser

$$h(F) = \ln(1 - F), \quad \alpha(\lambda) = -\lambda, \quad g(x) = x, \quad \beta(\lambda) = 0.$$

Le graphe de probabilités est donné par le nuage de points $(x_i^*, \ln(1 - \frac{i}{n}))$ et devrait se trouver autour d'une droite d'équation $y = -\lambda x$ (si la durée de vie d'une ampoule suit une loi exponentielle).



Hypothèse 2 : la durée de vie d'une ampoule suit une loi normale de paramètres (m, σ^2) . Posons $U = \frac{X-m}{\sigma}$ de sorte que $U \sim \mathcal{N}(0, 1)$. Alors on a la fonction de répartition de X :


$$F(x) = \mathbb{P}(X \leq x) = \mathbb{P}(U \leq \frac{x-m}{\sigma}) = \Phi(\frac{x-m}{\sigma})$$

où Φ est la fonction de répartition de la loi normale centrée réduite (on en a des tables).

On a alors la relation linéaire

$$\Phi^{-1}(F(x)) = \frac{x-m}{\sigma}$$

et on peut tracer le Q-Q plot.



La loi exponentielle semble être une hypothèse plus crédible que la loi normale.

Remarque. La plupart des méthodes graphiques pour visualiser les données ont des avantages et des inconvénients dus à la perception humaine. On trouve de nombreux exemples dans CLEVELAND, *Elements of graphing data*, Section 4.4.

1.3 Indicateurs statistiques

Si la variable étudiée est quantitative, en plus d'une représentation visuelle, on peut caractériser l'information contenu dans un échantillon par des nombres (comme la moyenne de l'échantillon). Ces nombres sont des **indicateurs statistiques**. Il y a deux types d'indicateurs statistiques :

1. Les **indicateurs de localisation** (ou **indicateurs de position**, **indicateurs de tendance centrale**), comme la médiane.
2. Les **indicateurs de dispersion** (ou **indicateurs de variabilité**), comme l'écart-type.

En général, on résume l'information d'un échantillon en choisissant un indicateur de localisation et un indicateur de dispersion.

Indicateurs de localisation

On considère un échantillon x composé des n observations $x_1, \dots, x_n \in \mathbb{R}$. On note x^* l'échantillon ordonné. Le but d'un indicateur de localisation est de résumer tout l'échantillon x en un unique nombre, censé être représentatif des observations. On va donner ici trois indicateurs de localisation et évaluer leur pertinence.

Définition 1.7. La **moyenne empirique** $\bar{x}$ de l'échantillon est la moyenne arithmétique des observations :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

La **médiane empirique** de l'échantillon est un nombre $\tilde{x}$ tel qu'il y a autant d'observations inférieures à $\tilde{x}$ qu'il y a d'observations supérieures à $\tilde{x}$. Si n est pair, plusieurs nombres satisfont cette propriété, et par convention on pose

$$\tilde{x} = \begin{cases} x_{(n+1)/2}^* & \text{si } n \text{ est impair,} \\ \frac{1}{2} (x_{n/2}^* + x_{n/2+1}^*) & \text{si } n \text{ est pair.} \end{cases}$$

Le **milieu de gamme** $\hat{x}$ est la moyenne arithmétique des deux observations extrêmes :

$$\hat{x} = \frac{x_1^* + x_n^*}{2}.$$

Exemple 1.8. Dans l'exemple des ampoules,

- La moyenne empirique est $\bar{x} = 83,15$ jours.
- La médiane empirique est $\tilde{x} = 62,2$ jours.
- Le milieu de gamme est $\hat{x} = 128,35$ jours.

Remarque.

- La moyenne empirique de l'échantillon x converge vers l'espérance de la variable aléatoire X quand $n \rightarrow \infty$. Ainsi, la moyenne correspond à la valeur qu'aurait chaque donnée si la distribution était uniforme. La médiane empirique sépare l'échantillon en deux : en tirant une observation au hasard, on a autant de chances d'être au-dessous de la médiane que d'être au-dessus (une chance sur deux).
- La moyenne est plus sensible aux valeurs aberrantes que la médiane. C'est parfois un avantage de la médiane, car il existe souvent des erreurs de mesures ou des cas extrêmes qui faussent les observations. Dans l'exemple des ampoules, la moyenne est supérieure à la médiane car il existe un petit nombre d'ampoules ayant une durée de vie nettement supérieure à la majeure partie des autres. Quand la distribution est symétrique (loi normale par exemple), moyenne et médiane empiriques sont proches.

On pourrait essayer de trouver LE meilleur indicateur de localisation. Un indicateur de localisation c est censé représenter les observations x_i , donc on va mesurer la distance $d(x, c)$ entre les observations x_i et c . Trouver le meilleur indicateur, c'est trouver l'indicateur c qui minimise cette distance $d(x, c)$. Voici trois manières de mesurer cette distance :

$$d_1(x, c) = \frac{1}{n} \sum_{i=1}^n (x_i - c)^2, \quad d_2(x, c) = \frac{1}{n} \sum_{i=1}^n |x_i - c|, \quad d_3(x, c) = \max_{i=1}^n |x_i - c|.$$

Proposition 1.9.

- Pour d_1 , le meilleur indicateur est la moyenne empirique $\bar{x}$.
- Pour d_2 , le meilleur indicateur est la médiane empirique $\tilde{x}$.
- Pour d_3 , le meilleur indicateur est le milieu de gamme $\hat{x}$.

Démonstration. On fait la démonstration pour d_1 . À x fixé, la fonction d_1 est continue en c et vérifie

$$\lim_{c \rightarrow \pm\infty} = +\infty.$$

De plus, la fonction est dérivable par rapport à c . Il suffit donc d'étudier les points critiques de d_1 . On dérive :

$$\frac{\partial}{\partial c} d_1(x, c) = \frac{-2}{n} \sum_{i=1}^n (x_i - c) = -2(\bar{x} - c).$$

La dérivée s'annule en un unique point $c = \bar{x}$. C'est le minimum de la fonction d_1 .

Pour d_2 , on ne peut pas dériver si $c \in \{x_1, \dots, x_n\}$. Supposons que ce ne soit pas le cas. Alors

$$\frac{\partial}{\partial c} d_2(x, c) = \frac{1}{n} \left(\sum_{i=1}^n \mathbb{1}_{x_i > c} - \sum_{i=1}^n \mathbb{1}_{x_i < c} \right) = \frac{1}{n} \sum_{i=1}^n (\mathbb{1}_{x_i > c} - \mathbb{1}_{x_i < c}).$$

La dérivée s'annule lorsqu'il y a autant de x_i inférieurs à c que de x_i supérieurs à c , c'est-à-dire lorsque $c = \tilde{x}$. $\square$

Indicateurs de dispersion

Un indicateur de dispersion est un nombre censé mesurer à quel point les données sont étalées. Il est souvent utilisé de pair avec un indicateur de localisation, et permet donc de mesurer à quel point l'indicateur de localisation est fidèle aux données. C'est pourquoi on peut utiliser les distances d_k définies plus haut, qui mesurent l'erreur des indicateurs correspondants.

Définition 1.10.

1. La **variance empirique** s^2 de l'échantillon x est

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

où $\bar{x}$ est la moyenne empirique.

2. La **déviations absolue moyenne** de l'échantillon x est

$$\delta = \frac{1}{n} \sum_{i=1}^n |x_i - \tilde{x}|$$

où $\tilde{x}$ est la médiane empirique.

3. L'**étendue** de l'échantillon x est

$$r = x_n^* - x_1^*$$

où x^* est l'échantillon ordonné.

Variance et écart-type

On a vu au-dessus que la moyenne est l'indicateur de localisation qui minimise la variance empirique.

On peut aussi calculer la variance par la formule

$$s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2.$$

Définition 1.11. L'écart-type s de l'échantillon x est la racine carrée de la variance empirique :

$$s = \sqrt{s^2}.$$

L'écart-type est souvent utilisé car il s'exprime dans la même unité que les données, ce qui n'est pas le cas de la variance.

Les quantiles empiriques

Les quantiles empiriques sont des valeurs qui partagent l'échantillon ordonné en parties égales.

Définition 1.12. Soit $k \in \mathbb{N}^*$ et $j \in \{1, \dots, k-1\}$. Le j -ième quantile empirique d'ordre k de l'échantillon x est


$$q_{j/k} = \begin{cases} \frac{1}{2} \left(x_{j\frac{n}{k}}^* + x_{j\frac{n}{k}+1}^* \right) & \text{si } jn/k \text{ est entier} \\ x_{\lfloor j\frac{n}{k} \rfloor + 1}^* & \text{sinon.} \end{cases}$$

Exemple 1.13. Le médiane est le premier quantile empirique d'ordre 2. Les quantiles d'ordre 4 sont appelés **quartiles**, ceux d'ordre 10 sont les **déciles** et ceux d'ordre 100 sont les **centiles**.

Définition 1.14. L'écart interquartile EI est la largeur de l'intervalle entre le premier et le troisième quartile :

$$\text{EI} = q_{3/4} - q_{1/4}.$$

Exemple 1.15. Les diagrammes en boîte à moustache représentent, sur le même graphique, la médiane, les quartiles $q_{1/4}$ et $q_{3/4}$, et les valeurs extrêmes. Pour l'exemple des ampoules, on a :



Remarque. D'autres conventions sont parfois utilisées pour définir les limites des boîtes à moustaches (par exemple, $q_{1/4} - 1.5EI$ et $q_{3/4} + 1.5EI$).