

Chapitre 2

Estimation ponctuelle

On dispose de données $x_1, \dots, x_n$ dont on suppose qu'elles sont la réalisation de n variables aléatoires $X_1, \dots, X_n$ indépendantes et identiquement distribuées. On fait l'hypothèse que l'on connaît la famille de lois des X_i , mais que cette famille dépend d'un paramètre θ qui nous est inconnu. On note

$$X_i \sim \mathcal{D}(\theta).$$

On cherche à estimer le paramètre θ en donnant une valeur $\hat{\theta}$ qui soit la plus proche possible de θ .

Exemple 2.1. On dispose d'une pièce de monnaie dont on veut mesurer l'équilibre. On lance $n = 100$ fois la pièce. On note $x_i = 1$ si le i -ème lancer tombe sur PILE, $x_i = 0$ si c'est FACE. On suppose qu'un lancer de pièce de monnaie est la réalisation d'une variable aléatoire de loi de Bernoulli $\mathcal{B}(p)$ de paramètre $p \in [0, 1]$. Si $p \neq 1/2$, alors la pièce est truquée. On veut estimer le paramètre p . Une estimation intuitive de p serait

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Exemple 2.2. Problème du tank allemand.

<https://www.theguardian.com/world/2006/jul/20/secondworldwar.tvandradio>
[https://fr.wikipedia.org/wiki/Problème_du_char_d'assaut_allemand](https://fr.wikipedia.org/wiki/Probl%C3%A8me_du_char_d%27assaut_allemand)

De manière générale, une estimation sera toujours fonction des données x_i . Ce sera donc une statistique :

Définition 2.3. Une **statistique** t est une fonction des observations x_i :

$$\begin{aligned} t &: \mathbb{R}^n &\longrightarrow &\mathbb{R}^m \\ x = (x_1, \dots, x_n) &\longmapsto &t(x) = (t_1(x), \dots, t_m(x)). \end{aligned}$$

Exemple 2.4. La moyenne empirique $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ est une statistique. La variance empirique $s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ est une statistique. Le couple de quartiles $(q_{1/4}, q_{3/4})$ est une statistique.

Remarque. Puisque les observations x_i sont des réalisations de variables aléatoires X_i , la statistique $t(x_1, \dots, x_n)$ est aussi la réalisation d'une variable aléatoire, à savoir $T = t(X_1, \dots, X_n)$. La variable aléatoire T est elle-même appelée **statistique**.

Définition 2.5. Un **estimateur** d'une quantité $\theta \in E$ est une statistique T à valeur dans E . Une **estimation** de θ est la réalisation t d'un estimateur de θ .

Exemple 2.6. Dans l'exemple de la pièce, $\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i$ est l'estimation correspondant à l'estimateur $T = \frac{1}{n} \sum_{i=1}^n X_i$.

Remarque. On note souvent $t_n = t(x_1, \dots, x_n)$ et $T_n = t(X_1, \dots, X_n)$. Cette notation permet en particulier d'étudier le comportement de la statistique lorsque la taille de l'échantillon grandit. Par exemple, on peut être intéressé par la limite de t_n quand n tend vers $+\infty$ (voir Section 2.3).

2.1 Méthode des moments

Il arrive souvent que le paramètre d'une famille de loi soit lié à l'espérance ou à la variance de cette loi. Par exemple, l'espérance d'une loi de Bernoulli de paramètre p est p , et l'espérance d'une variable aléatoire de loi exponentielle de paramètre λ est $\frac{1}{\lambda}$. Pour ces lois, avoir un estimateur de l'espérance ou de la variance permet donc d'avoir un estimateur du paramètre. On va alors estimer l'espérance par la moyenne empirique, la variance par la variance empirique, etc. Cette méthode est appelée la **méthode des moments**.

Définition 2.7. Le **moment d'ordre** k d'une variable aléatoire X est l'espérance $\mathbb{E}[X^k]$.

Définition 2.8. Soit X une variable aléatoire de loi $\mathcal{D}(\theta)$ où $\theta = (\mathbb{E}[X], \mathbb{E}[X^2], \dots, \mathbb{E}[X^k])$. L'**estimateur de θ par la méthode des moments** est la statistique $\hat{\theta}^{\text{MM}}$ donnée par

$$\hat{\theta}^{\text{MM}} = \varphi(m_1(X), m_2(X), \dots, m_k(X))$$

où

$$m_j(X) = \frac{1}{n} \sum_{i=1}^n X_i^j$$

est le **moment empirique** d'ordre j .

Exemple 2.9. Dans l'exemple de la pièce, $\hat{p}_n = \bar{X}$ est l'estimateur de p par la méthode des moments. C'est la proportion de PILE dans l'échantillon. On reconnaît l'approche fréquentiste qui estime une probabilité par une proportion. Plus généralement, l'estimateur donné par

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

définit la **moyenne empirique** des observations.

Exemple 2.10. Si les X_i suivent une loi exponentielle de paramètre λ , alors l'espérance de X_i est $\frac{1}{\lambda}$. On a donc $\lambda = \frac{1}{\mathbb{E}[X_i]}$. L'estimateur de λ par la méthode des moments est :

$$\hat{\lambda}_n = \frac{1}{\bar{X}_n}.$$

Exemple 2.11. Si les X_i suivent une loi normale $\mathcal{N}(\mu, \sigma^2)$, alors $\mathbb{E}[X_i] = \mu$ et $\text{Var}[X] = \sigma^2$. On a donc l'estimateur de μ par la méthode des moments

$$\hat{\mu}_n = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i,$$

mais également un estimateur $\hat{\sigma}_n^2$ de σ^2 par la méthode des moments d'ordre deux :

$$\hat{\sigma}_n^2 = S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

L'estimateur S_n^2 est la **variance empirique** des données.

Exemple 2.12. L'espérance de vie est parfois modélisée par une variable aléatoire X de loi Gamma $\Gamma(k, \theta)$ où

$$\mathbb{E}[X] = \frac{k}{\theta} \quad \text{et} \quad \text{Var}[X] = \frac{k}{\theta^2}.$$

On en déduit que

$$k = \frac{\mathbb{E}[X]^2}{\text{Var}[X]} \quad \text{et} \quad \theta = \frac{\mathbb{E}[X]}{\text{Var}[X]}.$$

On peut donc estimer k et θ par la méthode des moments avec

$$\hat{k}_n = \frac{\bar{X}_n^2}{S_n^2} \quad \text{et} \quad \hat{\theta}_n = \frac{\bar{X}_n}{S_n^2}$$

où $\bar{X}_n$ est la moyenne empirique et S_n^2 est la variance empirique de l'échantillon.

2.2 Méthode du maximum de vraisemblance

Le paramètre θ d'une loi $\mathcal{D}(\theta)$ ne s'exprime pas toujours comme une fonction des moments. Pire : la loi $\mathcal{D}(\theta)$ pourrait ne pas admettre de moment du tout (c'est le cas de la loi de Cauchy par exemple). On peut quand même trouver un estimateur via la méthode du maximum de vraisemblance.

Définition 2.13. La **fonction de vraisemblance** (ou **vraisemblance**) pour l'échantillon $x_1, \dots, x_n$ sous la famille de lois $\mathcal{D}(\theta)$ est donnée par :

$$\mathcal{L}(\theta; x_1, \dots, x_n) = \begin{cases} \mathbb{P}_\theta[X_1 = x_1, \dots, X_n = x_n] & \text{pour une loi discrète,} \\ f_{\theta; X_1, \dots, X_n}(x_1, \dots, x_n) & \text{pour une loi continue,} \end{cases}$$

où $\mathbb{P}_\theta$ et f_θ sont respectivement la fonction de masse et la densité de $\mathcal{D}(\theta)$. La fonction de vraisemblance est une fonction de θ , et on note $\mathcal{L}(\theta)$ lorsque le contexte le permet.

Remarque. On voit ici la différence entre le point de vue probabiliste et le point de vue statistique. Pour les probabilistes, θ est donné et la fonction de masse (ou la densité) est une fonction des x_i . Pour les statisticiens, les x_i sont données, et la vraisemblance est une fonction de θ .

Définition 2.14. Un **estimateur de maximum de vraisemblance** de θ est une statistique $\hat{\theta}^{MV}$ qui maximise la vraisemblance $\mathcal{L}$:

$$\hat{\theta}^{MV} = \operatorname{argmax} \mathcal{L}(\theta).$$

Proposition 2.15. Soient $x_1, \dots, x_n$ des données indépendantes et identiquement distribuées. Alors

$$\mathcal{L}(\theta) = \begin{cases} \prod_{i=1}^n \mathbb{P}_{\theta}[X = x_i] & \text{pour une loi discrète,} \\ \prod_{i=1}^n f_{\theta;X}(x_i) & \text{pour une loi continue.} \end{cases}$$

Définition 2.16. La **log-vraisemblance** ℓ est le logarithme de la vraisemblance $\mathcal{L}$:

$$\ell = \log \mathcal{L}.$$

Proposition 2.17. L'estimateur de maximum de vraisemblance maximise aussi la log-vraisemblance.


Exemple 2.18. On considère les données suivantes, dont on suppose qu'elles sont la réalisation de $n = 15$ variables aléatoires indépendantes de loi de Bernoulli $\mathcal{B}(p)$.

$$1 \quad 1 \quad 1 \quad 1 \quad 0 \quad 1 \quad 1 \quad 1 \quad 1 \quad 0 \quad 1 \quad 0 \quad 1 \quad 1 \quad 1$$

On va estimer p par la méthode du maximum de vraisemblance. La fonction de vraisemblance est

$$\mathcal{L}(p; x_1, \dots, x_n) = \prod_{i=1}^n \mathbb{P}_p[X_i = x_i] = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}.$$

on a le graphe suivant pour $\mathcal{L}(p)$:



On veut maximiser la vraisemblance. Pour faciliter les calculs, on considère la log-vraisemblance :

$$\ell(p) = \log \mathcal{L}(p; y_1) = \log \binom{15}{12} + 12 \log p + 3 \log(1 - p).$$

On dérive :

$$\ell'(p) = \frac{12}{p} - \frac{3}{1-p}.$$

Et on résout :

$$\ell'(\hat{p}) = 0 \iff \frac{12}{\hat{p}} = \frac{3}{1-\hat{p}} \iff 12(1-\hat{p}) = 3\hat{p} \iff 12 = 15\hat{p} \iff \hat{p} = \frac{12}{15}.$$

On a donc l'estimation de maximum de vraisemblance :

$$\hat{p}^{MV} = \frac{12}{15} = 0.8.$$

Remarque. Ici, l'estimateur de maximum de vraisemblance est le même que l'estimateur de la méthode des moments, mais ce n'est pas le cas en général.

2.3 Qualité d'un estimateur

Biais

Le biais mesure l'écart ($\hat{\theta}_n - \theta$) entre un estimateur $\hat{\theta}_n$ et le paramètre θ qu'il est censé estimer. Comme $\hat{\theta}_n$ est une variable aléatoire et que θ est déterministe, on passe la différence dans l'espérance pour obtenir une quantité déterministe : le biais.

Définition 2.19. Soit $\hat{\theta}_n$ un estimateur de θ . Le **biais** de $\hat{\theta}_n$ est la quantité

$$b(\hat{\theta}_n) = \mathbb{E}[\hat{\theta}_n - \theta].$$

L'estimateur $\hat{\theta}_n$ est **biaisé** si $b(\hat{\theta}_n) \neq 0$. Il est **sans biais** si $b(\hat{\theta}_n) = 0$.

Remarque. Comme θ est déterministe, on a

$$b(\hat{\theta}_n) = \mathbb{E}[\hat{\theta}_n] - \theta.$$

Exemple 2.20. La moyenne empirique

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

est sans biais.

Exemple 2.21. La variance empirique

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

est biaisée :

$$b(S_n^2) = \frac{-1}{n} \text{Var}[X].$$

Remarque. Si $\hat{\theta}_n$ est biaisé et qu'on sait calculer son biais $b(\hat{\theta}_n)$, alors l'estimateur

$$\tilde{\theta}_n = \hat{\theta}_n - b(\hat{\theta}_n)$$

est sans biais. Malheureusement, le biais dépend souvent de θ lui-même.

Erreur quadratique

Définition 2.22. L'erreur quadratique moyenne (ou **risque quadratique**) de l'estimateur $\hat{\theta}_n$ est la quantité

$$R(\hat{\theta}_n) = \mathbb{E}[(\hat{\theta}_n - \theta)^2].$$

Proposition 2.23 (Décomposition biais-variance). Soit $\hat{\theta}_n$ un estimateur de θ . Alors

$$R(\hat{\theta}_n) = b(\hat{\theta}_n)^2 + \text{Var}[\hat{\theta}_n].$$

Démonstration. On a

$$\begin{aligned} R(\hat{\theta}_n) &= \mathbb{E}[(\hat{\theta}_n - \theta)^2] \\ &= \mathbb{E}[(\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n] + \mathbb{E}[\hat{\theta}_n] - \theta)^2] \\ &= \underbrace{\mathbb{E}[(\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n])^2]}_{\text{Var}[\hat{\theta}_n]} + 2 \underbrace{\mathbb{E}[\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n]]}_{0} (\mathbb{E}[\hat{\theta}_n] - \theta) + \underbrace{(\mathbb{E}[\hat{\theta}_n] - \theta)^2}_{b(\hat{\theta}_n)}. \end{aligned}$$

□

Corollaire 2.24. Si $\hat{\theta}_n$ est un estimateur sans biais, alors $R(\hat{\theta}_n) = \text{Var}[\hat{\theta}_n]$.

Convergence

On doit pouvoir dire que plus les données sont nombreuses, plus l'estimation est précise, et que si l'échantillon est infiniment grand, l'estimateur donne la vraie valeur. On a donc besoin d'une notion de convergence. Or il existe plusieurs notions de convergence pour une variable aléatoire. On s'intéresse ici à la convergence en moyenne quadratique.

Définition 2.25. L'estimateur $\hat{\theta}_n$ **converge en moyenne quadratique** vers θ si

$$\lim_{n \rightarrow \infty} \mathbb{E}[(\hat{\theta}_n - \theta)^2] = 0.$$

Autrement dit, $R(\hat{\theta}_n) \rightarrow 0$. Dans ce cas, on note

$$\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{L^2} \theta.$$

Proposition 2.26. L'estimateur $\hat{\theta}_n$ converge en moyenne quadratique vers θ si et seulement si son biais et sa variance tendent vers 0. Un estimateur sans biais converge en moyenne quadratique si et seulement si sa variance tend vers 0.

Démonstration. On utilise la décomposition biais-variance. □

Quantité d'information

Définition 2.27. La **quantité d'information de Fisher** $\mathcal{I}_n(\theta)$ apportée par les données $x_1, \dots, x_n$ sur le paramètre θ est

$$\mathcal{I}_n(\theta) = \text{Var} \left[\frac{\partial}{\partial \theta} \log \mathcal{L}(\theta; X_1, \dots, X_n) \right].$$

Proposition 2.28 (Frechet-Darmois-Cramer-Rao). Soit $T_n = \varphi(X_1, \dots, X_n)$ un estimateur de θ tel que $\mathcal{I}_n(\theta)$ existe et

$$\frac{\partial}{\partial \theta} \mathbb{E}_\theta[T_n] = \int \frac{\partial}{\partial \theta} \varphi(t_1, \dots, t_n) f_\theta(t_1) \cdots f_\theta(t_n) dt.$$

Alors,

$$\text{Var}[T_n] \geq \frac{\left(\frac{\partial}{\partial \theta} \mathbb{E}_\theta[T_n]\right)^2}{\mathcal{I}_n[\theta]}.$$

En particulier, si T_n est sans biais, alors

$$\text{Var}[T_n] \geq \frac{1}{\mathcal{I}_n[\theta]}.$$

Proposition 2.29. Soit T_n un estimateur sans biais de θ tel que $\text{Var}[T_n] = \frac{1}{\mathcal{I}_n(\theta)}$. Alors T_n est un **estimateur sans biais de variance minimale**.

Exemple 2.30. Dans le modèle de Bernoulli, la moyenne empirique est un estimateur sans biais de variance minimale.

Applications

Proposition 2.31. La moyenne empirique $\bar{X}_n$ est un estimateur sans biais et converge en moyenne quadratique vers $\mathbb{E}[X]$.

Démonstration. Comme les X_i sont indépendantes et identiquement distribuées,

$$\mathbb{E}[\bar{X}_n] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} n \mathbb{E}[X] = \mathbb{E}[X].$$

Donc $b(\bar{X}_n) = 0$.

Le risque quadratique est donné par la décomposition biais-variance :

$$R(\bar{X}_n) = \text{Var}[\bar{X}_n] = \text{Var}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n^2} n \text{Var}[X] = \frac{\text{Var}[X]}{n}.$$

On a donc $R(\bar{X}_n) \rightarrow 0$, donc

$$\bar{X}_n \xrightarrow[n \rightarrow \infty]{L^2} \mathbb{E}[X].$$

□

Proposition 2.32. La variance estimée

$$S_n'^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

est un estimateur sans biais et converge en moyenne quadratique vers $\text{Var}[X]$.

Démonstration. On rappelle que la variance empirique est biaisée :

$$\mathbb{E}[S_n^2] = \frac{n-1}{n} \text{Var}[X].$$

Or,

$$S_n'^2 = \frac{n}{n-1} S_n^2$$

donc

$$\mathbb{E}[S_n'^2] = \frac{n}{n-1} \mathbb{E}[S_n^2] = \text{Var}[X]$$

et la variance estimée est sans biais. De plus, on peut montrer que

$$\text{Var}[S_n'^2] = \frac{1}{n(n-1)} \left((n-1) \mathbb{E}[(X - \mathbb{E}[X])^4] - (n-3) \text{Var}[X]^2 \right).$$

Cette quantité tend vers 0, donc la variance estimée converge en moyenne quadratique vers la variance de X . $\square$

Remarque. L'estimateur de maximum de vraisemblance est asymptotiquement sans biais et, asymptotiquement, $\text{Var}[\hat{\theta}^{MV}] \leq \text{Var}[\hat{\theta}^{MM}]$. Pour ces raisons, il est préféré à l'estimateur des moments lorsque la quantité de données est grande.