

Chapitre 3

Intervalles de confiance

Supposons que nous voulions estimer un paramètre $\theta \in \mathbb{R}$ à partir de données. Un estimateur $\hat{\theta}_n$ de θ a *de bonnes chances* d'être *proche* du paramètre théorique. Pour expliciter ces notions de *bonnes chances* et de *proximité*, on va estimer le paramètre par un intervalle plutôt que par un nombre. La longueur de l'intervalle précisera la notion de *proximité*, tandis que la probabilité que le paramètre soit dans l'intervalle précisera la notion de *bonnes chances*.

Définition 3.1. Un **intervalle de confiance** de **seuil** $\alpha \in [0, 1]$ pour le paramètre θ est un intervalle aléatoire I tel que

$$\mathbb{P}[\theta \in I] = 1 - \alpha. \quad (3.1)$$

La probabilité $(1 - \alpha)$ est appelé **niveau** de confiance.

Remarque. La terminologie “confiance” sous-entend que α est petit : c’est un risque, une probabilité d’erreur.

Remarque. Ici, le paramètre θ n’est pas aléatoire, seul l’intervalle I l’est. Si on pose $I = [Z_1, Z_2]$, alors Z_1 et Z_2 sont des variables aléatoires. Par exemple, on a parfois

$$I = [\hat{\theta} - \epsilon_\alpha, \hat{\theta} + \epsilon_\alpha]$$

où $\hat{\theta}$ est un estimateur de θ et ϵ_α est calculé pour satisfaire l’équation (3.1).

Remarque. Avec $\alpha = 0.05$ et $I = [Z_1, Z_2]$, on peut dire :

$$\theta \text{ a } 95\% \text{ de chances d'être entre } Z_1 \text{ et } Z_2.$$

Mais si on calcule les réalisations z_1 et z_2 à partir des données, on ne peut pas dire :

$$\theta \text{ a } 95\% \text{ de chances d'être entre } z_1 \text{ et } z_2$$

car θ , z_1 et z_2 sont déterministes. Il vaut mieux dire :

$$\text{On est confiant à } 95\% \text{ que } \theta \text{ soit entre } z_1 \text{ et } z_2.$$

Remarque. Pour un seuil α fixé, il est parfois difficile de trouver un intervalle I qui satisfait l’égalité de l’équation (3.1). Il peut être plus facile de trouver un intervalle J tel que

$$\mathbb{P}[\theta \in J] \geq 1 - \alpha.$$

On dira aussi de J qu’il est un intervalle de confiance.

3.1 Intervalles de confiance pour les paramètres d'une loi normale

Exemple 3.2. On cherche à tester des boîtes de médicaments en pilules pour déterminer la quantité moyenne d'agent actif dans chaque pilule. Un prélèvement sur 30 pilules au hasard a trouvé que la moyenne empirique est de 9.7mg avec une variance empirique corrigée de 0.5mg². On voudrait un intervalle I autour de 9.7mg tel qu'on soit sûr à 95% que la vraie quantité d'agent actif soit dans cet intervalle. On fait l'hypothèse que la quantité d'agent actif suit une loi normale.

On suppose que les données $x_1, \dots, x_n$ sont les réalisations de n variables aléatoires $X_1, \dots, X_n$ indépendantes et de loi normale $\mathcal{N}(\mu, \sigma^2)$. Pour simplifier les notations, on pose $X \sim \mathcal{N}(\mu, \sigma^2)$.

Lemme 3.3.

1. Soit $X \sim \mathcal{N}(\mu, \sigma^2)$ et soient $a, b \in \mathbb{R}$. Alors $aX + b \sim \mathcal{N}(a\mu + b, (a\sigma)^2)$.
2. Soient $X_1, \dots, X_n$ indépendantes de loi $\mathcal{N}(\mu, \sigma^2)$. Alors $\sum_{i=1}^n X_i \sim \mathcal{N}(n\mu, n\sigma^2)$.

Démonstration.

1. Posons $Y = aX + b$, soient f_X, f_Y les densités respectives de X et Y et soient F_X, F_Y les fonctions de répartition respectives de X et Y . On a

$$f_Y(t) = F'_Y(t).$$

Supposons que $a > 0$. Alors

$$F_Y(t) = F_X\left(\frac{t-b}{a}\right) = F_X(\varphi(t))$$

avec $\varphi(t) = \frac{t-b}{a}$. On a

$$\frac{d}{dt}F_X(\varphi(t)) = F'_X(\varphi(t))\varphi'(t) = f_X\left(\frac{t-b}{a}\right) \times \frac{1}{a}.$$

Donc

$$f_Y(t) = \frac{1}{a}f_X\left(\frac{t-b}{a}\right)$$

Si $a < 0$, alors

$$F_Y(t) = 1 - F_X\left(\frac{t-b}{a}\right)$$

et le même raisonnement donne

$$f_Y(t) = \frac{-1}{a}f_X\left(\frac{t-b}{a}\right).$$

Dans les deux cas,

$$\begin{aligned} f_Y(t) &= \frac{1}{|a|}f_X\left(\frac{t-b}{a}\right) \\ &= \frac{1}{|a|} \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(\frac{-\left(\frac{t-b}{a} - \mu\right)^2}{2\sigma^2}\right) \\ &= \frac{1}{\sqrt{2\pi}a^2\sigma^2} \exp\left(\frac{-(t - (a\mu + b))^2}{2a^2\sigma^2}\right) \end{aligned}$$

ce qui donne bien la densité de la loi $\mathcal{N}(a\mu + b, (a\sigma)^2)$. Si $a = 0$, alors $Y = b$ est déterministe et suit donc une loi normale de variance 0 et de moyenne b .

2. Cette propriété se démontre à l'aide du produit de convolution.

□

Corollaire 3.4. Soient $X_1, \dots, X_n$ indépendantes de loi $\mathcal{N}(\mu, \sigma^2)$ et soit

$$U = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}.$$

Alors

$$U \sim \mathcal{N}(0, 1).$$

Démonstration. Voir TD.

□

Intervalle de confiance pour la moyenne (variance connue)

On a vu en TD que $\bar{X}_n$ est l'ESBVM de μ .

Proposition 3.5. Un intervalle de confiance de seuil α pour la moyenne de la loi normale $\mathcal{N}(\mu, \sigma^2)$ est donné par

$$I = \left[\bar{X}_n - \frac{\sigma}{\sqrt{n}} u_\alpha, \bar{X}_n + \frac{\sigma}{\sqrt{n}} u_\alpha \right]$$

où $u_\alpha \in \mathbb{R}_+$ est défini par

$$\Phi(u_\alpha) = 1 - \frac{\alpha}{2}$$

et Φ est la fonction de répartition de la loi normale centrée réduite.

Démonstration. On calcule

$$\mathbb{P}[\mu \in I] = \mathbb{P}[|\bar{X}_n - \mu| \leq \frac{\sigma}{\sqrt{n}} u_\alpha] = \mathbb{P}\left[\frac{\sqrt{n}}{\sigma} |\bar{X}_n - \mu| \leq u_\alpha\right].$$

Or,

$$\frac{\sqrt{n}}{\sigma} (\bar{X}_n - \mu) = \frac{1}{\sigma\sqrt{n}} \sum_{i=1}^n (X_i - \mu) \sim \mathcal{N}(0, 1)$$

(d'après le Lemme 3.3). Ainsi, avec $U = \frac{\sqrt{n}}{\sigma} (\bar{X}_n - \mu)$,

$$\mathbb{P}[\mu \in I] = \mathbb{P}[|U| \leq u_\alpha] = \mathbb{P}[-u_\alpha \leq U \leq u_\alpha] = \Phi(u_\alpha) - \Phi(-u_\alpha).$$

Par symétrie,

$$\Phi(-u_\alpha) = 1 - \Phi(u_\alpha)$$

donc (par définition de u_α),

$$\mathbb{P}[\mu \in I] = 1 - \alpha.$$

□

Définition 3.6. Soit $\mathcal{D}$ une loi de probabilité et soit $p \in [0, 1]$. Le **quantile d'ordre p pour la loi $\mathcal{D}$** est le nombre u qui vérifie

$$F_{\mathcal{D}}(u) = p$$

où $F_{\mathcal{D}}$ est la fonction de répartition de $\mathcal{D}$.

Exemple 3.7. Dans le calcul de l'intervalle de confiance ci-dessus, u_α est le quantile d'ordre $1 - \frac{\alpha}{2}$ pour la loi normale centrée réduite.

Remarque. L'intervalle de confiance ci-dessus suppose que l'on connaisse la variance σ^2 . C'est rarement le cas en pratique.

Intervalle de confiance pour la moyenne (variance inconnue)

Théorème 3.8 (Fisher). Soient $X_1, \dots, X_n$ indépendantes de même loi $\mathcal{N}(\mu, \sigma^2)$ et soient la moyenne empirique et la variance estimée :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad S_n'^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

Alors

$$\frac{\bar{X}_n - \mu}{S_n' / \sqrt{n}} \sim t(n-1)$$

où $t(n-1)$ est la loi de Student à $n-1$ degrés de liberté.

Proposition 3.9. Un intervalle de confiance de seuil α pour la moyenne de la loi normale $\mathcal{N}(\mu, \sigma^2)$ est donné par

$$I = \left[\bar{X}_n - \frac{S_n'}{\sqrt{n}} t_{n-1, \alpha}, \bar{X}_n + \frac{S_n'}{\sqrt{n}} t_{n-1, \alpha} \right]$$

où $t_{n-1, \alpha}$ est le quantile d'ordre $1 - \frac{\alpha}{2}$ pour la loi de Student à $(n-1)$ degrés de liberté :

$$F_{n-1}^t(t_{n-1, \alpha}) = 1 - \alpha/2.$$

Démonstration. Faisons comme si nous ne connaissions pas le résultat. On cherche I tel que

$$\mathbb{P}[\mu \in I] = 1 - \alpha. \quad (3.2)$$

Posons

$$I = [\bar{X}_n - \epsilon_\alpha, \bar{X}_n + \epsilon_\alpha]$$

et cherchons la valeur de ϵ_α qui vérifie l'Équation (3.2). On a

$$\begin{aligned} \mu \in I &\iff \mu \in [\bar{X}_n - \epsilon_\alpha, \bar{X}_n + \epsilon_\alpha] \\ &\iff |\bar{X}_n - \mu| \leq \epsilon_\alpha \\ &\iff \frac{\sqrt{n}}{S_n'} |\bar{X}_n - \mu| \leq \frac{\sqrt{n}}{S_n'} \epsilon_\alpha. \end{aligned}$$

Or le théorème de Fisher donne la loi de $\frac{\sqrt{n}}{S_n'} (\bar{X}_n - \mu)$. En posant F_{n-1} la fonction de répartition de la loi de Student à $(n-1)$ degrés de liberté,

$$\begin{aligned} \mathbb{P} \left[\frac{\sqrt{n}}{S_n'} |\bar{X}_n - \mu| \leq \frac{\sqrt{n}}{S_n'} \epsilon_\alpha \right] &= F_{n-1} \left(\frac{\sqrt{n}}{S_n'} \epsilon_\alpha \right) - F_{n-1} \left(\frac{-\sqrt{n}}{S_n'} \epsilon_\alpha \right) \\ &= 2F_{n-1} \left(\frac{\sqrt{n}}{S_n'} \epsilon_\alpha \right) - 1 \end{aligned}$$

par symétrie de la loi de Student. Ainsi, on a

$$\mathbb{P}[\mu \in I] = 2F_{n-1}\left(\frac{\sqrt{n}}{S'_n}\epsilon_\alpha\right) - 1$$

et on peut résoudre l'Équation (3.2) :

$$\begin{aligned}\mathbb{P}[\mu \in I] = 1 - \alpha &\iff 2F_{n-1}\left(\frac{\sqrt{n}}{S'_n}\epsilon_\alpha\right) - 1 = 1 - \alpha \\ &\iff F_{n-1}\left(\frac{\sqrt{n}}{S'_n}\epsilon_\alpha\right) = 1 - \frac{\alpha}{2} \\ &\iff \epsilon_\alpha = \frac{S'_n}{\sqrt{n}}F_{n-1}^{-1}(1 - \alpha/2).\end{aligned}$$

□

Intervalle de confiance pour la variance

Théorème 3.10 (Fisher). Soient $X_1, \dots, X_n$ indépendantes de même loi $\mathcal{N}(\mu, \sigma^2)$ et soient la moyenne empirique et la variance estimée :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad S_n'^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

Alors

$$\frac{1}{\sigma} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{(n-1)S_n'^2}{\sigma^2} \sim \chi_{n-1}^2$$

où χ_{n-1}^2 est la loi du chi-deux à $(n-1)$ degrés de liberté.

Proposition 3.11. Un intervalle de confiance de seuil α pour la variance de la loi normale $\mathcal{N}(\mu, \sigma^2)$ est donné par

$$I = \left[\frac{(n-1)S_n'^2}{z_{n-1, \alpha/2}}, \frac{(n-1)S_n'^2}{z_{n-1, 1-\alpha/2}} \right]$$

où

$$\mathbb{P}[Z > z_{n-1, x}] = x$$

pour tout $Z \sim \chi_{n-1}^2$ et $x \in [0, 1]$.

Démonstration. On cherche deux variables aléatoires Z_1 et Z_2 telles que

$$\mathbb{P}[Z_1 \leq \sigma^2 \leq Z_2] = 1 - \alpha. \quad (3.3)$$

On va utiliser le théorème de Fisher : si Z_1 et Z_2 sont strictement positives, alors

$$\mathbb{P}[Z_1 \leq \sigma^2 \leq Z_2] = \mathbb{P}\left[\frac{(n-1)S_n'^2}{Z_2} \leq Z \leq \frac{(n-1)S_n'^2}{Z_1}\right]$$

On pose donc

$$Z_2 = \frac{(n-1)S_n'^2}{a} \quad \text{et} \quad Z_1 = \frac{(n-1)S_n'^2}{b}$$

avec $0 < a \leq b$. Alors Z_1 et Z_2 sont (presque sûrement) strictement positives, et

$$\mathbb{P}[Z_1 \leq \sigma^2 \leq Z_2] = \mathbb{P}[a \leq Z \leq b].$$

D'après le théorème de Fisher, $Z \sim \chi_{n-1}^2$, donc

$$\mathbb{P}[Z_1 \leq \sigma^2 \leq Z_2] = F_{n-1}(b) - F_{n-1}(a).$$

Ainsi, l'équation (3.3) est équivalente à

$$F_{n-1}(b) - F_{n-1}(a) = 1 - \alpha. \quad (3.4)$$

Il existe une infinité de manière de distribuer le risque pour résoudre l'équation (3.4). On choisit d'équilibrer le risque et on résout

$$\begin{cases} F_{n-1}(b) = 1 - \frac{\alpha}{2}, \\ F_{n-1}(a) = \frac{\alpha}{2}. \end{cases} \quad (3.5)$$

Les tables de la loi du chi-deux donnent la réciproque de la fonction $1 - F_{n-1}$. On va donc résoudre le système suivant, équivalent à (3.5) :

$$\begin{cases} 1 - F_{n-1}(b) = \frac{\alpha}{2}, \\ 1 - F_{n-1}(a) = 1 - \frac{\alpha}{2}. \end{cases} \quad (3.6)$$

La solution à l'équation (3.6) est

$$a = z_{n-1, 1-\alpha/2} \quad \text{et} \quad b = z_{n-1, \alpha/2}.$$

Finalement, en reprenant la définition de a et b ,

$$Z_1 = \frac{(n-1)S_n'^2}{z_{n-1, \alpha/2}} \quad \text{et} \quad Z_2 = \frac{(n-1)S_n'^2}{z_{n-1, 1-\alpha/2}}$$

donnent l'intervalle de confiance attendu. □

3.2 Intervalle de confiance pour une proportion

Exemple 3.12. Une élection oppose deux candidats ALICE et BOB. ALICE commande un sondage à un institut qui interroge 800 personnes sur leur intention de vote. Sur ces 800 personnes, 420 déclarent vouloir voter pour ALICE. On utilise le modèle de Bernoulli $\{\mathcal{B}(p) \mid p \in [0, 1]\}$. On a vu que la moyenne empirique $\hat{p}_n$ est un estimateur sans biais de variance minimale de p . Ici, $\hat{p}_n = 52.5\%$. On cherche un intervalle de confiance pour cette valeur.

Théorème 3.13 (central limite). Soit $(X_n)_{n \in \mathbb{N}^*}$ une suite de variables aléatoires indépendantes et identiquement distribuées d'espérance μ et de variance σ^2 . Alors la suite $(Z_n)_{n \in \mathbb{N}^*}$ de variables aléatoires

$$Z_n := \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

converge en loi vers $Z \sim \mathcal{N}(0, 1)$:

$$\forall x \in \mathbb{R}, \quad \mathbb{P}[Z_n \leq x] \xrightarrow{n \rightarrow +\infty} \Phi(x)$$

où Φ est la fonction de répartition de la loi gaussienne centrée réduite.

Proposition 3.14. Un intervalle de confiance asymptotique pour le paramètre p dans le modèle de Bernoulli est

$$I = \left[\hat{p}_n - \frac{u_\alpha}{2\sqrt{n}}, \hat{p}_n + \frac{u_\alpha}{2\sqrt{n}} \right]$$

où $\hat{p}_n$ est la moyenne empirique et $u_\alpha \in \mathbb{R}_+$ est défini par

$$u_\alpha = \Phi^{-1}(1 - \alpha/2)$$

avec Φ la fonction de répartition de la loi normale centrée réduite.

Démonstration. On pose

$$Z_n = \frac{\hat{p}_n - p}{\sigma/\sqrt{n}}.$$

Par le théorème central limite, pour tout $x, y \in \mathbb{R}$,

$$\mathbb{P}[x \leq Z_n \leq y] \xrightarrow{n \rightarrow +\infty} \Phi(y) - \Phi(x).$$

Or

$$\mathbb{P}[x \leq Z_n \leq y] = \mathbb{P}\left[\hat{p}_n - \frac{\sigma y}{\sqrt{n}} \leq p \leq \hat{p}_n - \frac{\sigma x}{\sqrt{n}}\right].$$

On centre l'intervalle de confiance autour de $\hat{p}_n$ en posant $x = -y$, et on équilibre les risques en posant $\Phi(y) = 1 - \frac{\alpha}{2}$, soit $y = u_\alpha$. Enfin, on remarque que $\sigma = \sqrt{p(1-p)}$ dépend de p , mais que pour tout $p \in [0, 1]$, on a $\sigma \leq 1/2$. On en déduit l'intervalle de confiance asymptotique. $\square$

Remarque. En pratique, pour $\alpha \leq 0.05$, n est assez grand si $np \geq 10$ et $n(1-p) \geq 10$.

Exemple 3.15. Dans l'exemple si dessus, un intervalle de confiance à 5% est donné par

$$I = [0.49, 0.56]$$

(on a pris $u_\alpha = 1.96$). On voit que l'intervalle contient des valeurs strictement plus petites que 0.5. Pour diminuer la taille de cet intervalle (pour le même seuil), on peut augmenter la taille de l'échantillon, au risque de voir $\hat{p}_n$ diminuer. On peut également augmenter le seuil, mais on sera moins sûr de l'intervalle.

Remarque. On aurait également pu remplacer σ par $\sqrt{\hat{p}_n(1-\hat{p}_n)}$ (méthode des moments).