

TD 5 : TESTS D'HYPOTHÈSES

EXERCICE 1 Traduire chacune de situations suivantes en un test paramétrique : établir une hypothèse nulle et une hypothèse alternative, donner un modèle statistique de la forme $\{\mathcal{D}(\theta) \mid \theta \in \Theta\}$, traduire les hypothèses en Θ_0 et Θ_1 et indiquer si le test sera simple, bilatéral ou unilatéral.

1. Votre usine fabrique des pièces truquées et des pièces non-truquées. Les pièces truquées ont 75% de chances de tomber sur PILE. Vous trouvez une pièce par terre dans votre usine. Toutes les pièces se ressemblent, mais vous voulez savoir si c'est une pièce truquée. Quitte à vous tromper, vous préféreriez ranger la pièce dans la catégorie TRUQUÉE.
2. Des amis vous invitent au restaurant, mais vous ne voulez contaminer personne avec le covid (il est plus important pour vous de ne contaminer personne que d'aller au restaurant). Vous disposez d'un appareil mesurant la charge virale dans un prélèvement biologique en calculant le Ct (*cycle threshold*) : le Ct est le cycle d'amplification de la PCR à partir duquel la quantité de virus présent dans l'échantillon est détectée. Cette valeur est inversement proportionnelle à la « charge virale » : plus le Ct est élevé, plus faible est la quantité d'ARN viral dans l'échantillon. Un Ct inférieur ou égal à 37 est le signe d'une contamination.
3. Vous êtes responsable d'une centrale d'appel : les clients appellent et sont mis en attente avant qu'un de vos agents ne puisse répondre. L'ancien système en place induisait un temps d'attente moyen $T_0 > 0$. Vous avez construit un nouveau système. Vous voulez tester si votre nouveau système réduit le temps d'attente. Quitte à vous tromper, vous préférez mettre en place le nouveau système car il résout d'autres problèmes.

Solution :

1.

$$\begin{cases} H_0 : \text{la pièce est truquée} \\ H_1 : \text{la pièce n'est pas truquée} \end{cases}$$

Un lacer de pièce ne peut prendre que deux valeurs, donc modèle $\{\mathcal{B}(p) \mid p \in \{0.5, 0.75\}\}$ donc test simple :

$$\begin{cases} \Theta_0 = \{0.75\} \\ \Theta_1 = \{0.5\} \end{cases}$$

2.

$$\begin{cases} H_0 : \text{vous portez le virus} \\ H_1 : \text{vous ne portez pas le virus} \end{cases}$$

On mesurera le nombre de cycles par échantillon, donc modèle $\{\mathcal{P}(\lambda) \mid \lambda > 0\}$, espérance λ , donc test unilatéral à droite

$$\begin{cases} \Theta_0 =]0, 37] \\ \Theta_1 =]37, +\infty[\end{cases}$$

Remarque : Comme λ est grand, on peut aussi utiliser une loi normale.

3.

$$\begin{cases} H_0: \text{le nouveau système réduit le temps d'attente} \\ H_1: \text{le nouveau système augmente le temps d'attente} \end{cases}$$

Un temps d'attente se modélise par une loi exponentielle, donc modèle : $\{\mathcal{E}(\lambda) \mid \lambda > 0\}$. Espérance $\frac{1}{\lambda}$, donc test unilatéral à gauche :

$$\begin{cases} H_0: \frac{1}{\lambda} < T_0 \\ H_1: \frac{1}{\lambda} \geq T_0 \end{cases} \quad \text{càd} \quad \begin{cases} \Theta_0 =]\frac{1}{T_0}, +\infty[\\ \Theta_1 =]-\infty, \frac{1}{T_0}] \end{cases}$$

EXERCICE 2 [STANISLAS PETROV, 26/09/1983]

Vous êtes affecté à la surveillance d'un système d'alerte anti-missiles dont voici le fonctionnement. Chaque jour, vous recevez 40 réalisations d'un signal $X_i = v + B_i$ où $v \in \mathbb{R}$ et $B_i \sim \mathcal{N}(0, 1)$ pour tout $i \in \{1, \dots, 40\}$. Les B_i sont indépendantes et modélisent un bruit qui vient s'ajouter à v . Si $v = 0$, vous n'avez rien à signaler. Si $v \neq 0$, votre pays est attaqué et vous devrez riposter, ce qui déclenchera un conflit nucléaire mondial.

Ce matin, vous avez reçu l'échantillon suivant :

0.01	1.01	1.01	0.01	1.01	-0.99	2.01	0.01
-0.99	-1.99	0.01	1.01	0.01	-0.99	-0.99	0.01
0.01	-0.99	0.01	-0.99	0.01	0.01	1.01	1.01
0.01	0.01	0.01	-0.99	-0.99	0.01	0.01	0.01
1.01	-0.99	1.01	0.01	-0.99	0.01	0.01	1.01

Après calculs, la moyenne empirique est $\bar{x} = -0.015$ et la variance empirique corrigée est $s'^2 = 0.69$.

1. Donnez la loi des X_i .
2. Donnez votre meilleure estimation $\hat{v}$ de v . Avez-vous $\hat{v} = 0$?
3. Déterminez deux hypothèses H_0 et H_1 en vue de prendre votre décision.
4. Déterminez un niveau de confiance $1 - \alpha$ qui vous semble adapté à la situation.
5. Établissez un test sous la forme d'une région critique W .
6. Donnez la conclusion de votre test.
7. Quelle est la p -valeur de votre test ?

Solution :

1. $X_i \sim \mathcal{N}(v, 1)$
2. $\hat{v} = \bar{X}$. Ici, $\bar{x} = -0.015 \neq 0$.
3. $H_0: v = 0$, $H_1: v \neq 0$.

4. $1 - \alpha = 99\%$.

5. $W = \left\{ |\bar{x}| > \frac{\sigma}{\sqrt{n}} u_\alpha \right\}$. Ici, $\frac{\sigma}{\sqrt{n}} u_\alpha \simeq 0.41$. On a donc

$$W = \{\bar{x} > 0.41\}$$

6. $T(x) = 0$.

7.

$$|\bar{x}| > \frac{\sigma}{\sqrt{n}} u_\alpha \iff \alpha > 2 \left(1 - \Phi \left(\frac{\sqrt{n} |\bar{x}|}{\sigma} \right) \right) \simeq 0.92$$

Avec nos données, la p -valeur est de 92% : il faudrait un seuil à 92% pour rejeter l'hypothèse nulle.

EXERCICE 3 Pour apaiser un certain type de maux de tête, on a l'habitude de traiter les malades avec un médicament A. Une étude statistique a montré que la durée de disparition de la douleur chez les malades traités avec A était une variable aléatoire de loi normale $\mathcal{N}(m_0, \sigma_0^2)$, avec $m_0 = 30$ minutes et $\sigma_0 = 5$ minutes. Un laboratoire pharmaceutique a conçu un nouveau médicament B et désire tester son efficacité. Pour cela, le nouveau médicament a été administré à 12 malades cobayes, et on a mesuré la durée de disparition de la douleur pour chacun d'entre eux :

25	28	20	32
17	24	41	28
25	30	27	24

Une étude de statistique descriptive sur ces données a amené les pharmacologues à considérer que cette durée était une variable aléatoire de loi normale $\mathcal{N}(m, \sigma^2)$. Établir un test de seuil $\alpha = 5\%$ sur l'efficacité du médicament B. Quitte à se tromper, on préférera ne pas commercialiser le médicament B.

Solution :

Hypothèses :

$$\begin{cases} H_0: \text{médicament B inefficace} \\ H_1: \text{médicament B efficace} \end{cases}$$

Modèle :

$$\left\{ \mathcal{N}(m, \sigma^2) \mid m \in \mathbb{R} \right\}, \quad \sigma \text{ inconnu}$$

Formalisation :

$$\begin{cases} H_0: m \geq m_0 \\ H_1: m < m_0 \end{cases}$$

Test unilatéral à gauche. Région critique :

$$W = \left\{ \bar{x} < m_0 - \frac{S'}{\sqrt{n}} t_{2\alpha} \right\}$$

Estimateurs :

$$\bar{x} \simeq 26.75, \quad s' \simeq 6.1$$

Quantile avec $\alpha = 0.05$ et $(n - 1) = 11$:

$$t_{2\alpha} = t_{0.95} \simeq 1.796$$

Calcul avec $\alpha = 0.05$

$$m_0 - \frac{s'}{\sqrt{n}} t_{2\alpha} = 30 - \frac{6.1}{\sqrt{12}} 1.796 \simeq 26.84$$

Résultat

$$T(x) = 1$$

EXERCICE 4 Une élection oppose deux candidats ALICE et BOB. ALICE commande un sondage à un institut qui interroge 800 personnes sur leur intention de vote. Sur ces 800 personnes, 420 déclarent vouloir voter pour ALICE. ALICE sera-t-elle élue ?

Solution :

Hypothèses

$$\begin{cases} H_0: \text{ALICE n'est pas élue} \\ H_1: \text{ALICE est élue} \end{cases}$$

Modèle : X_i i.i.d. avec $X_i = 1$ si vote pour ALICE

$$\{\mathcal{B}(p) \mid p \in [0, 1]\}$$

Hypothèses :

$$\begin{cases} H_0: p \leq \frac{1}{2} \\ H_1: p > \frac{1}{2} \end{cases}$$

Région critique (asymptotique) :

$$W = \left\{ \bar{x} > p_0 + \frac{u_{2\alpha} \sqrt{p_0(1-p_0)}}{\sqrt{n}} \right\}, \quad p_0 = \frac{1}{2}$$

Calculs avec $\alpha = 0.05$:

$$\bar{x} = 0.525, \quad p_0 + \frac{u_{2\alpha} \sqrt{p_0(1-p_0)}}{\sqrt{n}} \simeq 0.529$$

Donc $T(x) = 0$ avec $\alpha = 0.05$. p -valeur :

$$\alpha_c = 1 - \Phi \left(\frac{\sqrt{n}}{\sqrt{p_0(1-p_0)}} (\bar{x} - p_0) \right) \simeq 0.08$$

EXERCICE 5 Une étude sur la création d'entreprises vise à vérifier s'il y a une variabilité selon la saison de l'année. On a observé 52 créations d'entreprises en 2024 et la distribution selon les saisons est la suivante :

Printemps	Été	Automne	Hiver
10	21	8	13

Faire un test au niveau 10% pour vérifier s'il y a une influence de la saison.

Solution :

On note $N_1, \dots, N_4$ les effectifs. On pose H_0 : pas d'effet de la saison. Donc

$$\begin{cases} H_0 : (N_1, \dots, N_4) \sim \mathcal{M}(52, 0.25, 0.25, 0.25, 0.25) \\ H_1 : \text{sinon} \end{cases}$$

Région critique

$$W = \left\{ \sum_{i=1}^4 \frac{(n_i - \frac{n}{4})^2}{\frac{n}{4}} > z_{k-1, \alpha} \right\}$$

Calcul

$$\sum_{i=1}^4 \frac{(n_i - \frac{n}{4})^2}{\frac{n}{4}} = \frac{4}{n} \sum_{i=1}^4 (n_i - 13)^2 \simeq 7.54$$

Et d'après la table,

$$z_{k-1, \alpha} = z_{3, 0.1} \simeq 6.2514$$

Donc $T(x) = 1$: on rejette H_0 .

EXERCICE 6 Vous travaillez dans une biscuiterie qui fabrique des gâteaux individuels. Afin d'obtenir le label NUTRISCORE C, la teneur en sucres de vos gâteaux ne doit pas trop varier : on demande un écart-type de 2 grammes maximum. Après prélèvement sur la chaîne de production, vous mesurez la quantité de sucre (en grammes) dans 10 gâteaux :

15	16	17	18	18	19	20	21	18	18
----	----	----	----	----	----	----	----	----	----

On considère que ce poids en sucre suit une loi normale.

1. Déterminer avec une confiance de 95% si votre entreprise peut commercialiser le gâteau. Quitte à se tromper, votre entreprise préfère ne pas le commercialiser plutôt que d'être dans l'illégalité.
2. Quelle est la p -valeur de votre échantillon ?

Solution :

1. Hypothèses

$$\begin{cases} H_0: \text{écart-type trop grand} \\ H_1: \text{écart-type sous les deux grammes} \end{cases}$$

Modèle $\{\mathcal{N}(\mu, \sigma^2) \mid \sigma > 0\}$ (μ inconnue).

$$\begin{cases} H_0: \sigma^2 > 4 \\ H_1: \sigma^2 \leq 4 \end{cases}$$

Région critique :

$$W = \{(n-1)s'^2 \leq \sigma_0^2 z_{n-1,1-\alpha}\}$$

où $z_{n-1,1-\alpha}$ est le quantile d'ordre $\alpha = 0.05$. On a $\bar{x} = 18$ et $s'^2 \simeq 3.11$ donc

$$(n-1)s'^2 = 28$$

D'autre part,

$$\sigma_0^2 z_{n-1,1-\alpha} \simeq 4 \times 3.3251 \simeq 13.3$$

On ne rejette pas H_0 : les gâteaux doivent être re-fabriqués ($\alpha = 0.05$).

2. On calcule la p -valeur :

$$T(x) = 1 \iff \alpha \geq F\left(\frac{(n-1)s'^2}{\sigma_0^2}\right) \simeq 0.36$$

EXERCICE 7 On considère un échantillon $(x_1, \dots, x_n)$ sous le modèle $\{\mathcal{N}(\mu, \sigma^2) \mid \mu \in \mathbb{R}\}$ avec σ connu. Établir un test de seuil α pour les hypothèses

$$\begin{cases} H_0: & \mu = \mu_0 \\ H_1: & \mu \neq \mu_0. \end{cases}$$

Indication : Utilisez un intervalle de confiance.

EXERCICE 8 Démontrer la proposition du cours qui donne les régions critiques des tests de Student.

EXERCICE 9 Démontrer la proposition du cours qui donne les régions critiques pour la variance d'une loi normale.

EXERCICE 10 Détailler le calcul de la p -valeur donnée dans l'exemple du logiciel de PILE ou FACE.

